Universidad de Alcalá



Visión Artificial

Sistemas de Visión Artificial

Tema 3. Técnicas de segmentación

Autores: Sira Palazuelos, Luis M. Bergasa, Manuel Mazo, M. Ángel García, Marisol Escudero, J. Manuel Miguel

Departamento de Electrónica. Universidad de Alcalá.

Universidad de Alcalá

Índice

1. **Introducción**
2. **Segmentación basada en el histograma**
   - Umbralización
   - Métodos de *clustering: k-means*
3. **Segmentación basada en regiones**
   - Crecimiento de regiones (*region growing*)
   - División y fusión de regiones (*split and merge*)
   - Transformada *watershed*
4. **Detección de bordes**
5. **Segmentación basada en bordes**
   - Análisis local
   - Análisis global
6. **Detección de esquinas**



1. Introducción

Introducción

- **Segmentar una imagen consiste en dividirla en regiones u objetos de interés.**
- La segmentación adecuada depende del objetivo de la aplicación: una misma imagen puede segmentarse de distintas formas.
- Para ello se buscan **similitudes dentro de las regiones** y/o **diferencias entre regiones vecinas**, utilizando características como **intensidad, color, textura, movimiento o bordes.**
- Un **objeto** se identifica como una región formada por píxeles que presentan características suficientemente similares entre sí y diferenciadas de las regiones vecinas.
- **Imagen segmentada o mapa de etiquetas:**
  - cada píxel recibe una etiqueta que indica el objeto / la región a la que pertenece, p. ej.:
  - 0 → fondo.
  - 1, 2, 3, … → distintas regiones.

Imagen original



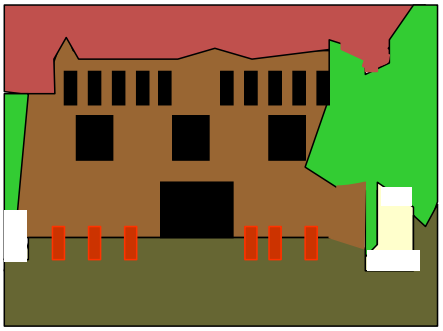
Imagen segmentada

0	0	0	0	0	0	0	0	0	0	0
0	1	1	1	0	0	0	0	0	0	0
0	1	1	1	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0
0	2	2	0	0	0	0	0	0	0	0
0	2	2	0	0	0	0	0	0	0	0
0	2	2	0	0	0	3	3	3	3	3
0	2	2	0	0	0	3	3	3	3	3
0	2	2	0	0	0	3	3	3	3	3
0	0	0	0	0	0	3	3	3	3	3

Introducción

- **La segmentación depende del objetivo de cada aplicación concreta**
  - **No** existe necesariamente una **única** segmentación correcta de una imagen.
  - La **elección de qué regiones u objetos distinguir depende de la tarea** que queramos resolver.
  - En esta escena podríamos querer segmentar, por ejemplo:
    - el edificio frente al resto de la escena,
    - puertas y ventanas,
    - personas,
    - árboles y vegetación,
    - suelo,
    - etc.

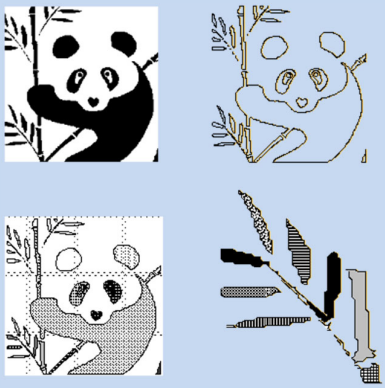




Introducción

- **¿En qué podemos basarnos para segmentar?**
  - Una vez definidos los objetos o regiones que nos interesan, necesitamos seleccionar las **características** que nos permitan distinguirlos. Para evaluar si una característica es válida para segmentar, valoraremos:
    - **Homogeneidad**: los píxeles de una misma región presentan características similares. Ej.: intensidad, color, textura o movimiento.
    - **Discontinuidad**: entre regiones diferentes aparecen cambios significativos de alguna característica. Ej.: bordes.
  - En este tema estudiaremos **técnicas de segmentación** basadas en:
    - **histograma/umbralización,**
    - **regiones,**
    - **bordes.**

¿Hay características que cumplan los criterios que nos permiten segmentar los objetos que necesitamos? La respuesta depende de la complejidad de la imagen…

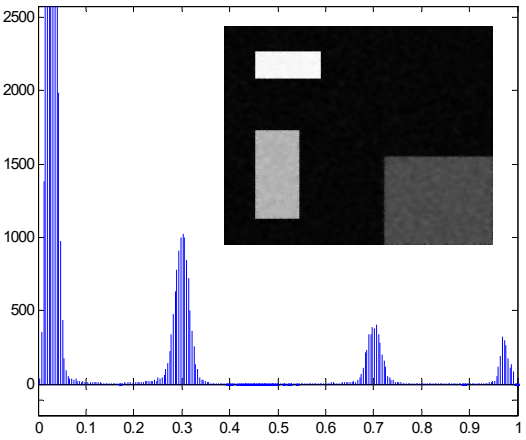


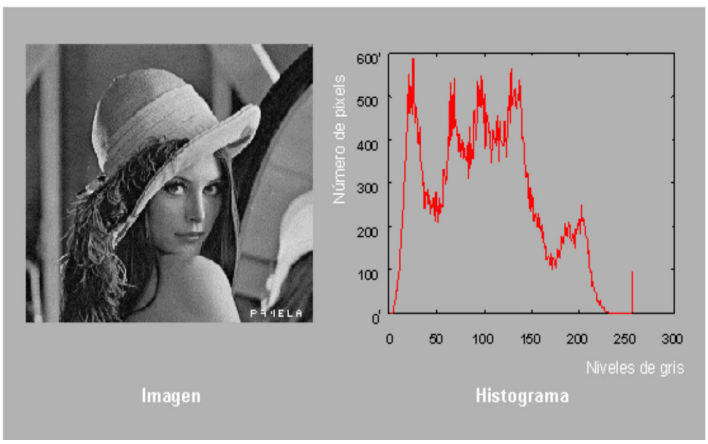


2. Segmentación basada en el histograma

Segmentación basada en histograma

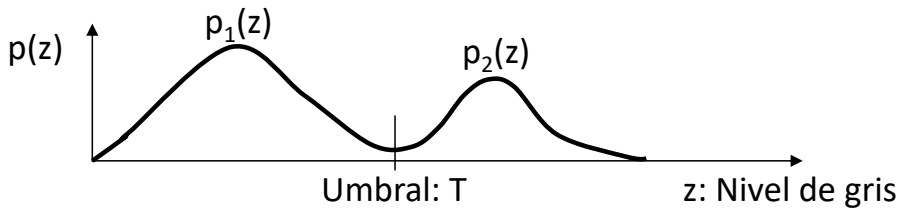
- Cuando los objetos o regiones de interés presentan **distribuciones de intensidad suficientemente diferentes**, estas pueden reflejarse en el histograma y utilizarse para segmentar la imagen.
- Cuanto mayor sea el **solapamiento** entre las distribuciones correspondientes a las distintas clases, más difícil será separarlas mediante el histograma.



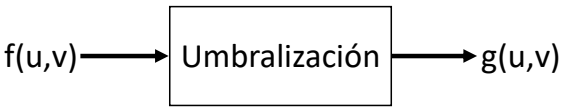


Segmentación basada en histograma
Conceptos básicos

- La **segmentación basada en el histograma** es el **modelo ideal** que utilizamos cuando las clases tienen niveles de gris distintos, que se reflejan en el histograma como **distribuciones diferenciadas**.
- Considera que cada **lóbulo** del histograma corresponde a la distribución de probabilidad de cada clase **objeto** en la imagen.
- Un ejemplo con 2 objetos podría ser:



- La **segmentación** puede realizarse asignando los píxeles a distintas clases en función de uno o varios **umbrales** de intensidad.



$$g(u,v) = \begin{cases} 255 & si \quad f(u,v) > T \\ 0 & si \quad f(u,v) \leq T \end{cases}$$

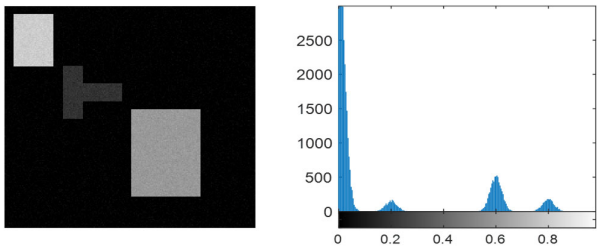
- **Problema: Cálculo del umbral!**

Segmentación basada en histograma
Tipos de umbralización

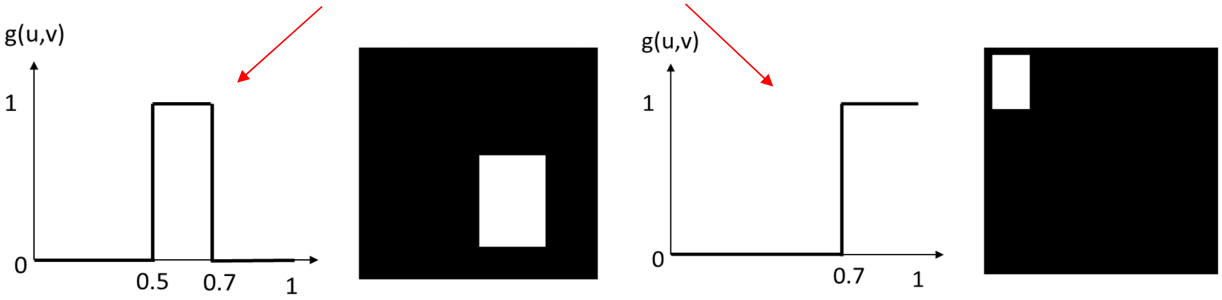
- **Tipos de umbralización** (veremos algunos en detalle a continuación):
  - Según el **número de clases** que queremos separar:
    - **Binaria:** dos clases → un umbral.
    - **Multinivel**: Si queremos **separar más de dos clases (N>**2) mediante umbralización, necesitaremos **N-1 umbrales**, T_i, con i = 1, …, N-1.
  - Según **cómo varía el umbral en la imagen**:
    - **Global**: el umbral tiene el **mismo valor** en toda la imagen.
    - **Local o adaptativa**: el valor del umbral es **diferente** en distintas partes de la imagen y se calcula en **función del entorno**.
  - Según **cómo se calculan los umbrales**:
    - **Supervisados** (obtenidos utilizando información previa sobre las clases). P. ej.: **distancia euclídea** a centroides o **teorema de Bayes**.
    - **No supervisados** (se obtienen automáticamente a partir de los datos) P. ej.: **Otsu**, **algoritmo *k-means,* algoritmo EM/GMM o** búsqueda de **máximos y mínimos** sobre el histograma.
  - Según las **características de la imagen utilizadas**:
    - **Una componente**: imagen en niveles de gris, por ejemplo.
    - **Varias componentes**: imagen en color o, en general, multicanal.

Segmentación basada en histograma
Umbralización global

- **Umbralización global:** A partir del histograma **global** de la imagen se obtienen uno o varios umbrales que se aplican a **todos** los píxeles:

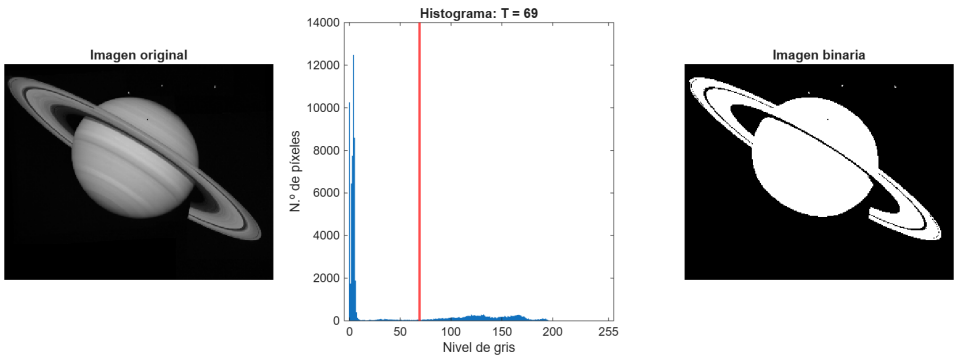


Funciones de umbralización



Segmentación basada en histograma
Umbralización global

- **Umbralización global:** ¿Cómo podemos **calcular automáticamente ese umbral global**?
- **Método de Otsu:**
  - Método **automático** y **no supervisado** para obtener un **umbral global**.
  - Recorre los posibles valores de umbral (T) y divide los píxeles en **dos** clases.
  - Para cada clase resultante calcula cuántos píxeles contiene, su valor medio y la separación entre las clases y selecciona el umbral que produce la **mejor separación** entre las dos clases: el valor que **maximiza la varianza entre clases / minimiza la varianza dentro de las clases**.
  - Funciona especialmente bien cuando el histograma presenta **dos clases suficientemente diferenciadas.**



Segmentación basada en histograma
Umbralización local

- **Umbralización local:**
  - Cuando la iluminación es diferente en distintas partes de la imagen, un **único** umbral global puede **no** segmentar correctamente en todas las zonas.
  - En la **umbralización local o adaptativa, el umbral varía** en las distintas partes: **se calcula para cada píxel o región** a partir de estadísticas de su entorno, como la media o la mediana.

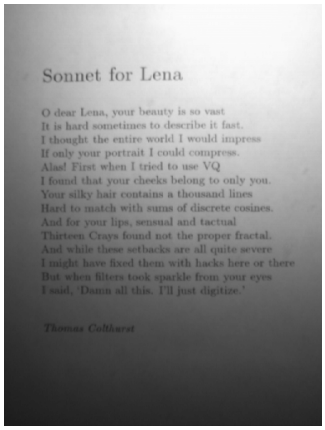


Imagen original

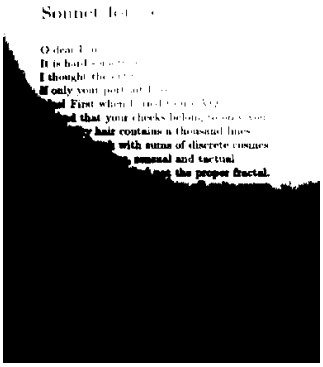


Imagen umbralizada con umbral global

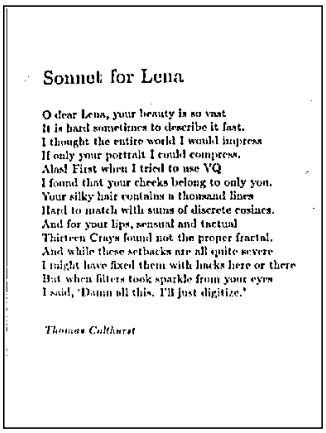
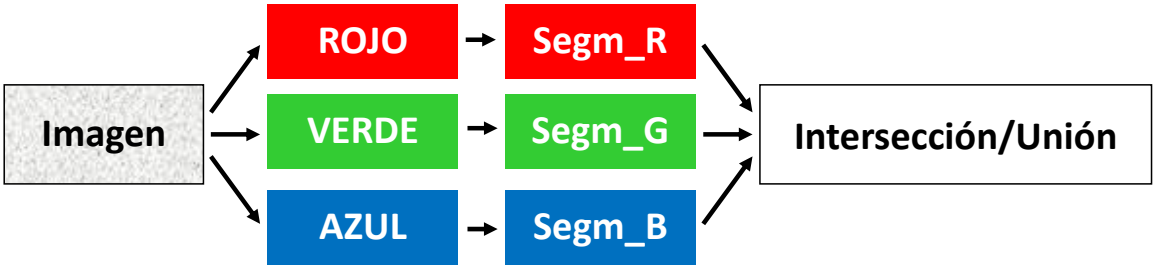


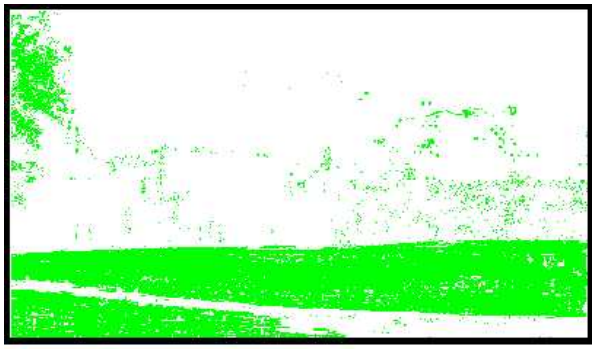
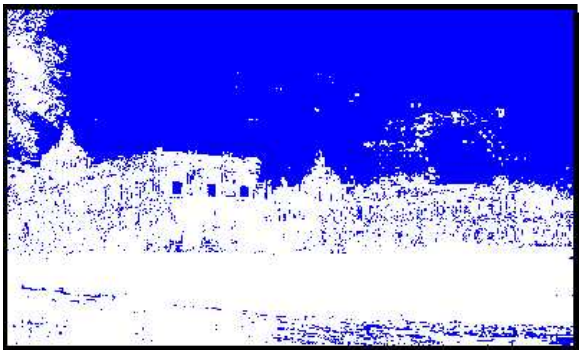
Imagen umbralizada con umbral local

Segmentación basada en histograma
Umbralización en color/multicanal

- **Umbralización en color/multicanal**
  - En una imagen en **color,** la segmentación puede realizarse en RGB o en otro espacio de color más adecuado para la aplicación (HSV, YCbCr, etc.).
  - Podemos **umbralizar** sobre una o varias componentes. P. ej., si la imagen es RGB, podemos umbralizar en R, G y B o solo en una o dos de ellas.
  - Las máscaras obtenidas para cada componente pueden combinarse, por ejemplo, mediante operaciones lógicas AND u OR.
  - Ej. con RGB:

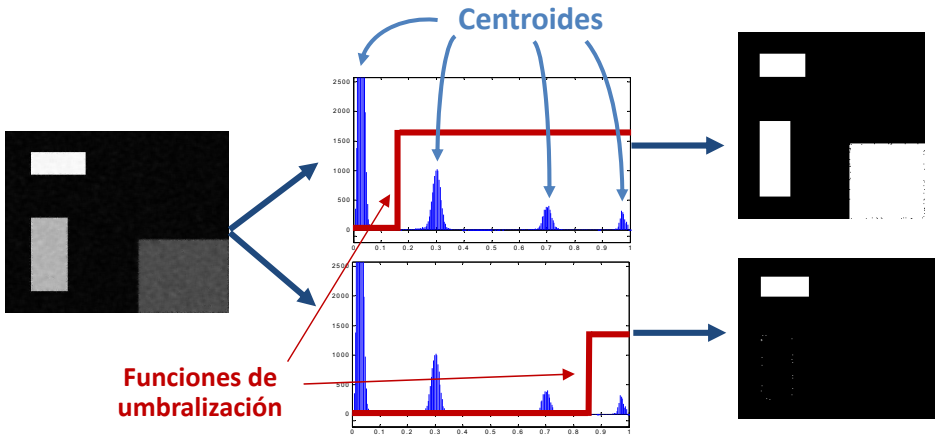


Segmentación basada en histograma
Umbralización en color/multicanal


Segmentación basada en histograma
Umbralización supervisada lineal

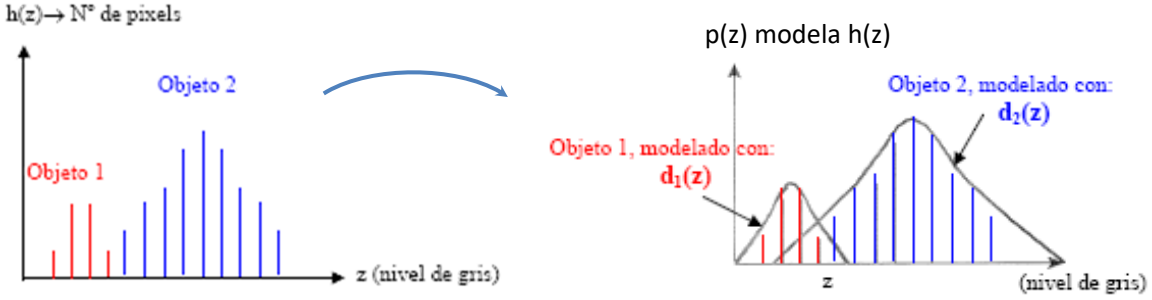
- Una vez vistos los tipos de umbralización y cómo aplicarlos, el problema es **cómo calcular los valores de los umbrales.**
- Una de las posibilidades es la **umbralización supervisada**: durante una etapa **previa** de entrenamiento se **proporciona al sistema información** sobre las clases y sus características, a partir de la cual pueden calcularse los umbrales.
- Consideraremos dos tipos de **umbralización supervisada (I)**:
  - **Umbralización supervisada lineal**: se calculan los **centroides** de las clases y se sitúan los umbrales en los **puntos medios entre centroides consecutivos**: **segmentación por distancia euclídea**.



Segmentación basada en histograma
Umbralización supervisada no lineal

- Consideraremos dos tipos de **umbralización supervisada (II)**:
  - **Umbralización supervisada no lineal**: cuando las clases presentan **distinta dispersión**, el punto medio entre sus centroides no tiene por qué minimizar el error de clasificación. Es necesario incorporar **más información sobre la distribución** de los niveles de gris de cada clase.
  - Se aproxima el histograma mediante una **suma ponderada de funciones de densidad de probabilidad** (fdp o pdf en inglés) de las distintas clases. Para el caso de un histograma bimodal, dos objetos (1 y 2) con lóbulos bien diferenciados:

$$p(z) = P_1 p_1(z) + P_2 p_2(z) = d_1(z) + d_2(z)$$



Donde:

z = variable aleatoria que representa el nivel de gris en la imagen,

$p_1(z)$ y $p_2(z)$ = funciones de densidad de probabilidad asociadas a los dos objetos del histograma,

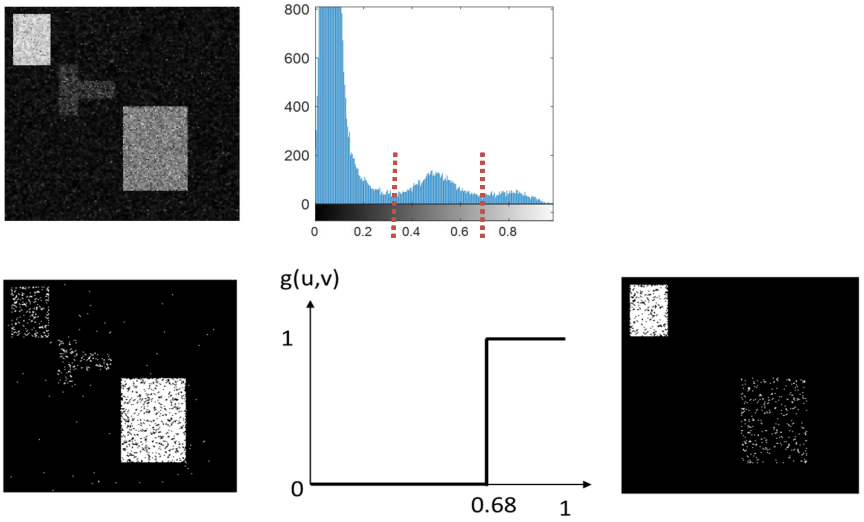
P_1 y P_2= probabilidades a priori de que un píxel pertenezca al objeto 1 y al 2 ($P_1 + P_2 = 1$).

$d_1(z) = P_1 p_1(z)$ y $d_2(z) = P_2 p_2(z)$: contribución ponderada de cada clase al modelo.

Universidad de Alcalá

Segmentación basada en histograma
Umbralización supervisada no lineal

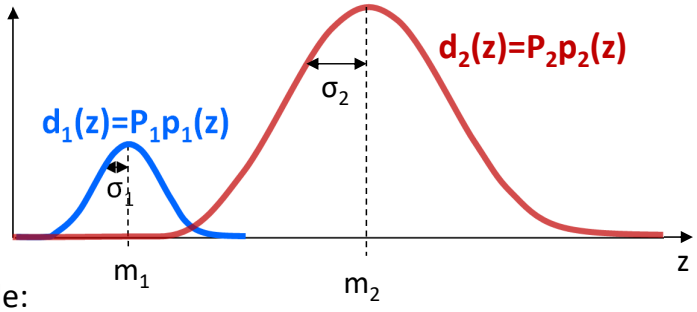
- Cuando las distribuciones de las clases se **solapan** (algo frecuente en imágenes reales), la segmentación mediante umbralización **no** puede ser perfecta: se pueden segmentar correctamente la mayoría de los píxeles, pero algunos se clasifican **erróneamente**.



Segmentación basada en histograma
Umbralización supervisada no lineal

- En el modelo no lineal ya **no** caracterizamos cada clase únicamente por su media, sino también por su dispersión. Es frecuente **aproximar las distribuciones mediante funciones gaussianas**:

$$p(z)=d_1(z)+d_2(z)=P_1p_1(z)+P_2p_2(z)$$



$$p_1(z)=\frac{1}{\sigma_1\sqrt{2\pi}}\exp\left[-\frac{(z-m_1)^2}{2\sigma_1^2}\right]$$

$$p_2(z)=\frac{1}{\sigma_2\sqrt{2\pi}}\exp\left[-\frac{(z-m_2)^2}{2\sigma_2^2}\right]$$

donde:

m_1, σ_1 y m_2, σ_2 = medias y desviaciones típicas de las fdps asociadas a las clases 1 y 2.

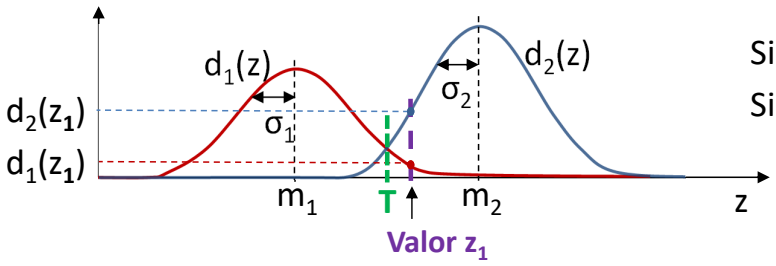
- Los **pesos**, P_1 y P_2, representan las probabilidades a priori de los objetos 1 y 2 y, en el conjunto de entrenamiento, pueden estimarse a partir de la proporción de píxeles correspondiente a cada objeto:
  - Objeto 2 más probable que objeto 1: $P_2 > P_1$
  - Clases equiprobables: $P_1 = P_2$ ...

Siempre: $P_1 + P_2 = 1$

Universidad de Alcalá

Segmentación basada en histograma
Umbralización supervisada no lineal

- Para clasificar un píxel de nivel de gris z_1, se calculan $d_1(z_1)$ y $d_2(z_1)$ y **se asigna el píxel a la clase que proporcione el mayor valor** $d_i(z_1)$:



Si $d_1(z_1) > d_2(z_1)$ → clase 1
Si $d_2(z_1) > d_1(z_1)$ → clase 2

- El **umbral óptimo** es aquel nivel z =T en el que el error de clasificación es mínimo y que cumple:

$$d_1(T) = d_2(T) \rightarrow P_1 \cdot p_1(T) = P_2 \cdot p_2(T)$$

- Una vez calculado el umbral, **no** es necesario aplicar la fórmula de cada gaussiana. El proceso de **clasificación** se reduce a **comparar el nivel de gris con dicho umbral**:

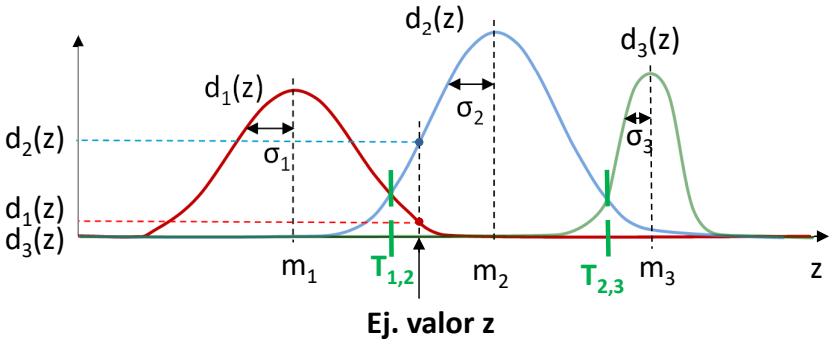
Si $z_1 < T$ → objeto 1
Si $z_1 > T$ → objeto 2

- Si $\sigma_1 = \sigma_2 = \sigma$ (histograma bimodal modelado con funciones gaussianas):

$$T=\frac{m_1+m_2}{2}+\frac{\sigma^2}{m_1-m_2}\ln\frac{P_2}{P_1}$$

Segmentación basada en histograma
Umbralización supervisada no lineal

- Para **histogramas multimodales** (con m objetos en la imagen):



$$p(z) = \sum_{i=1}^{m} P_i\, p_i(z)$$

$$\sum_{i=1}^{m} P_i = 1$$

- Cada píxel de nivel del gris z se asigna a la clase para la que $P_i \cdot p_i(z)$ sea máximo.
- Los **umbrales** óptimos entre clase y son los niveles de gris T que cumplen que:

$$P_k \cdot p_k(T_{kj}) = P_j \cdot p_j(T_{kj})$$

siendo T_{kj} el umbral de separación entre las clases k y j contiguas.

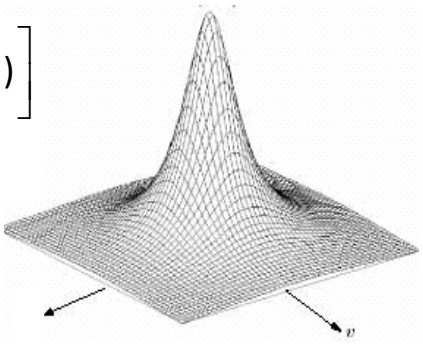
- Una vez elegidos los umbrales, no será necesario aplicar las fórmulas de las gaussianas: **compararemos el nivel de gris con los distintos umbrales**. **El píxel de nivel de gris *z* pertenece al objeto o clase *k-ésima* si** $T_{k-1\,k} < z < T_{k\,k+1}$.

Segmentación basada en histograma
Umbralización supervisada no lineal

- Hasta ahora hemos utilizado una única característica por píxel: el nivel de gris. Si utilizamos **varias características**, el mismo modelo probabilístico se extiende a **varias dimensiones**.
- Cada **color** de la imagen se representa con un **vector n-dimensional** de características ($\bar{z}$). El histograma pasa a ser n-dimensional.
- Ejemplo: gaussiana bidimensional

$$p_1(\bar{z}) = \frac{1}{(2\pi)^{\frac{n}{2}} |C_1|^{\frac{1}{2}}} \exp\left[-\frac{1}{2} (\bar{z} - \bar{\mu}_1)^T C_1^{-1} (\bar{z} - \bar{\mu}_1) \right]$$

donde $\bar{\mu}_1, C_1$ representan el vector de medias y la matriz de covarianza de la fdp asociada a la distribución de la clase 1 en el espacio de características.



Gaussiana bidimensional

Segmentación basada en histograma
Umbralización supervisada no lineal

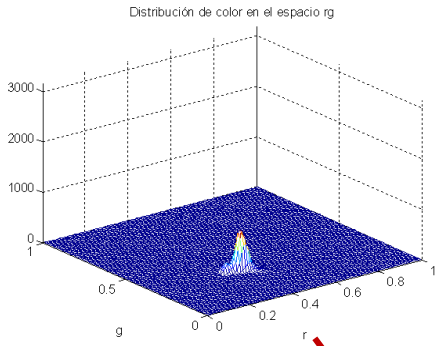
- Si queremos segmentar un objeto caracterizado por un **color suficientemente homogéneo**, podemos modelar su distribución mediante una función gaussiana en el espacio de color:
  - Cálculo de los parámetros del modelo a priori
  - Segmentación mediante umbral



Imagen original



Objeto a segmentar
(Selección de muestras)



m_S, C_S

Estimación de parámetros del modelo

$$f(x_j / skin) = \frac{1}{2\pi \mid C_S \mid^{0.5}} e^{-0.5(x_j - m_S)^T C_S^{-1} (x_j - m_S)}$$

$x_j \in$ skin si $f(x/skin) > T$

Segmentación



Imagen segmentada

Universidad de Alcalá

Segmentación basada en histograma
Umbralización supervisada no lineal

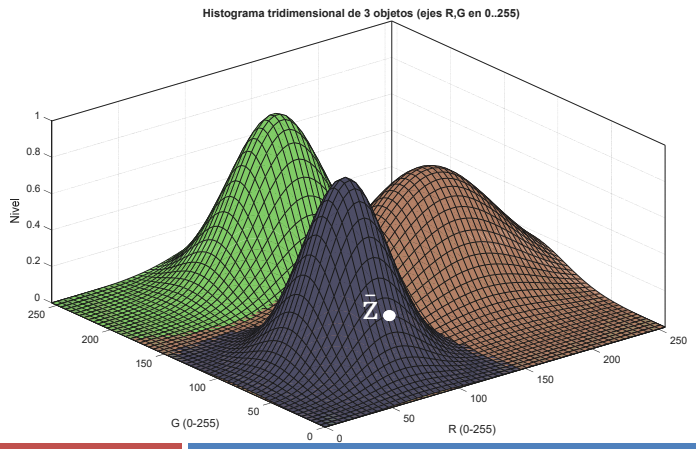
- El histograma n-dimensional de una imagen con m objetos se modelaría con la siguiente expresión:

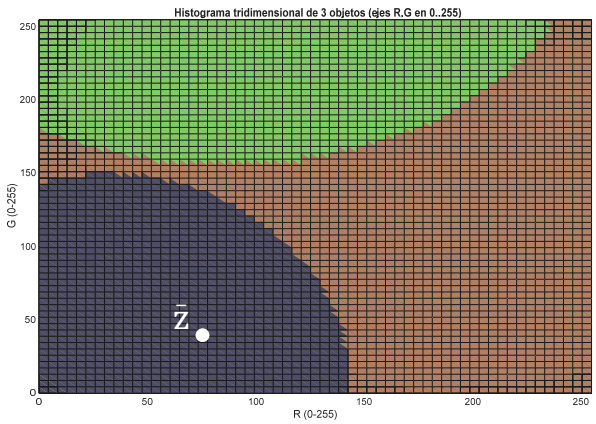
$$p(\bar{z}) = d_1(\bar{z}) + d_2(\bar{z}) + \ldots d_m(\bar{z}) = P_1 * p_1(\bar{z}) + P_2 * p_2(\bar{z}) + \ldots P_m * p_m(\bar{z})$$

donde: $P_1 + P_2 + \ldots\ldots P_m = 1$

$p_1(\bar{z}), p_2(\bar{z}), p_m(\bar{z})$ fdp n-dimensionales asociadas con los objetos 1, 2…. M

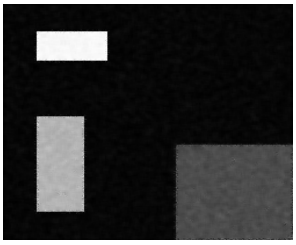
- El píxel de vector de características $\bar{z}$ pertenecería a la clase k-ésima si $d_k(\bar{z}) > d_j(\bar{z})$ siendo j = 1, 2, ... m y distinto de k.
- Ejemplo con 3 objetos, distribución gaussiana, fronteras de decisión no lineales:

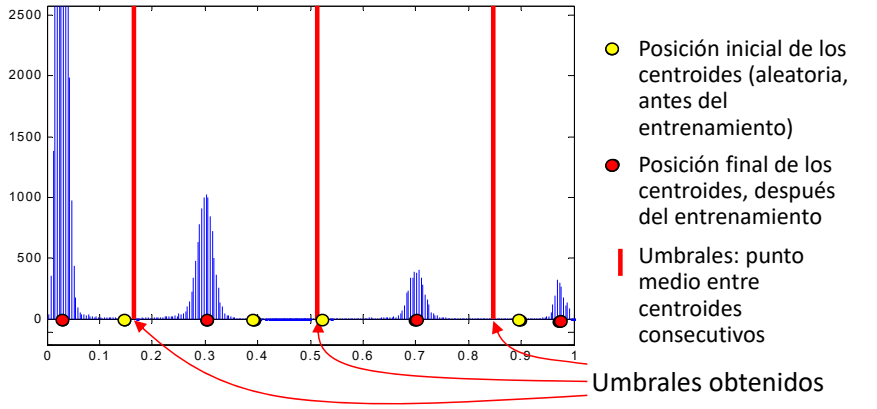




Segmentación basada en histograma
Umbralización no supervisada lineal

- Otra forma de calcular los umbrales es utilizar **algoritmos de *clustering***: **métodos no supervisados** que agrupan automáticamente los píxeles en clases a partir de sus características, **sin** proporcionar previamente la clase a la que pertenece cada píxel.
- **Umbralización no supervisada lineal:**
  - **Número de clases conocido *a priori*,**
  - Entrenamiento **no supervisado de centroides** (puntos promedio de cada clase),
  - Clasificación mediante **distancia euclídea** (lineal): umbrales en el punto medio entre cada par de centroides consecutivos.

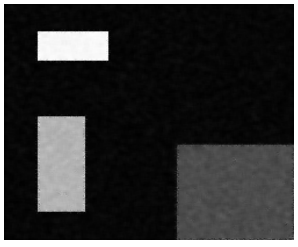


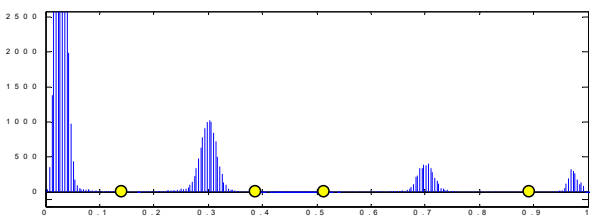


Métodos de *clustering*
Algoritmo k-means

- **Algoritmo *k-means*:**
  - Su objetivo es clasificar los píxeles {X} de la imagen en m clases $\{\alpha_1, \alpha_2, \alpha_m\}$.
  - Los píxeles se clasifican según su vector de características (nivel de gris, color, etc.).
  - ***K-means*** es un algoritmo de **clasificación no supervisada lineal** que asume que se conoce el número de clases, m, pero no la clase a la que pertenece cada muestra: dispone de las muestras y de sus características, pero **no conoce previamente sus etiquetas**.
- **Algoritmo de entrenamiento recursivo para encontrar el centroide de cada clase (I):**
  - **Paso 1:** Se eligen **m vectores** al **azar** entre los elementos a agrupar, que se utilizarán como valores iniciales de los **centroides de las m clases**:

$$\alpha_1 : z_1(0); \alpha_2 : z_2(0); \ldots; \alpha_m : z_m(0)$$





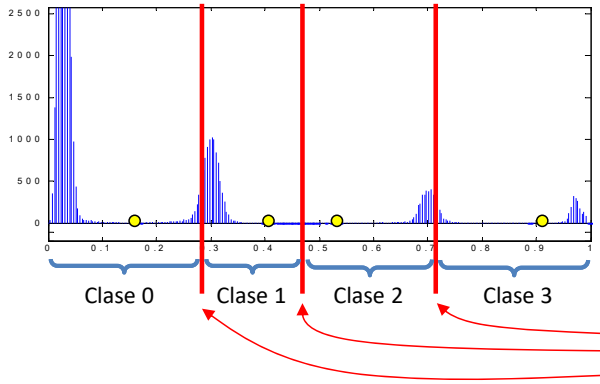
- **Algoritmo de entrenamiento recursivo para encontrar el centroide de cada clase (II):**
  - **Paso 2**: En la iteración t **se distribuyen todas las muestras entre las m clases, $\alpha_i(t)$,** asignando cada una a la clase del **centroide más cercano**.

$$\text{For } i = 1 \text{ to } N$$

$$x_i \in \alpha_j(t) \quad \text{si} \quad ||x_i - z_j(t)|| < ||x_i - z_k(t)||$$

$$\forall k = 1,2,\ldots,m / k \neq j$$

$$\text{End}\{\text{For}\}$$



- Posición inicial de los centroides (antes del entrenamiento, aleatoria)
- Umbrales: punto medio entre centroides consecutivos

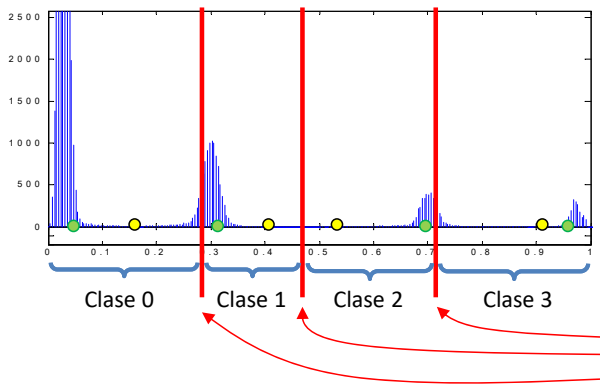
Umbrales correspondientes con esos centroides

- **Algoritmo de entrenamiento recursivo para encontrar el centroide de cada clase (III):**
  - **Paso 3**: Se **actualizan los centroides de las clases**, $z_k(t+1)$, llevando cada uno a la **media aritmética** de los píxeles que hayan sido asignados a su clase (α_k) en esta iteración, $\alpha_k(t)$:

$$z_k(t+1) = \frac{1}{N_k(t)} \sum_{i=1}^{N_k(t)} x_i \qquad ;k = 1,2,\ldots,m; N_k(t) : elementos\ de\ \alpha_k(t)$$

Con este proceso se busca minimizar la variación intracluster, es decir, la suma de las distancias cuadráticas de cada muestra al centroide de su clase:

$$J_k = \sum_{x \in \alpha_k(t)} \|X - z_k(t)\|^2 \quad k = 1,2,\ldots,m \quad (m\ es\ el\ n^o\ de\ clases)$$

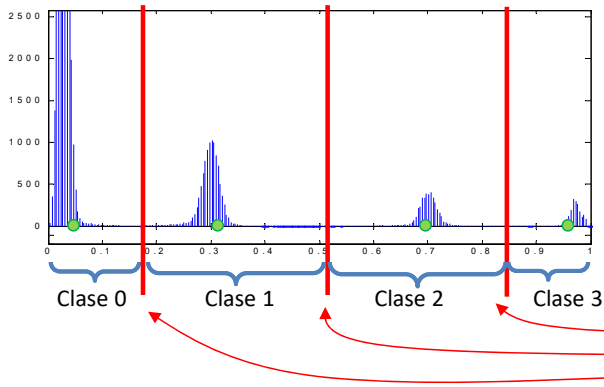


- Posición inicial de los centroides (antes del entrenamiento, aleatoria)
- Nuevos centroides calculados cada uno de ellos como la media de los elementos clasificados en su clase

Umbrales calculados con los centroides anteriores

- **Algoritmo de entrenamiento recursivo para encontrar el centroide de cada clase (IV):**
  - **Paso 4:** Se vuelve al paso 2 y se repiten iterativamente desde ahí hasta que los vectores prototipo (centroides) no cambien su posición cuando se actualicen, o hasta que el cambio de posición entre iteraciones esté por debajo de un umbral:

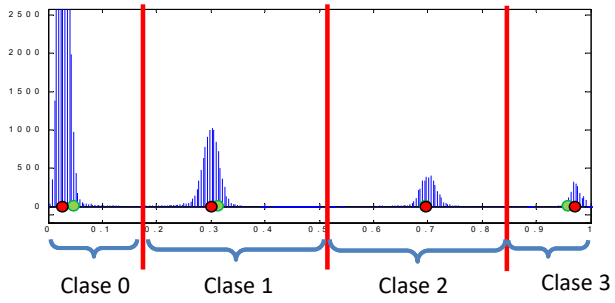
$$\sum_{j=1}^{m} ||z_j(t+1) - z_j(t)|| < \varepsilon$$



Nuevos centroides calculados como media de los clústeres generados

Nuevos umbrales

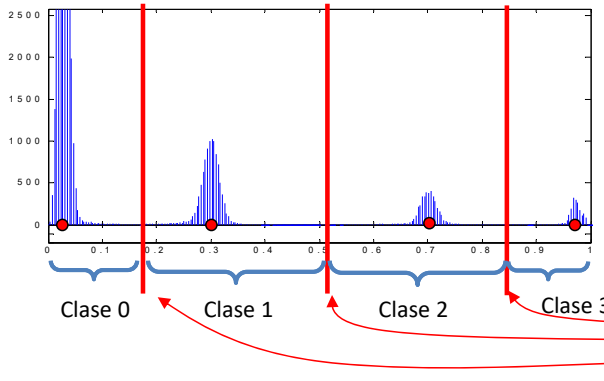
- **Algoritmo de entrenamiento recursivo para encontrar el centroide de cada clase (V):**
  - Siguiente iteración:



Centroides anteriores

Centroides siguientes

  - En la siguiente iteración no se modifica la posición de los centroides ni de los umbrales: se han alcanzado los **valores definitivos**.

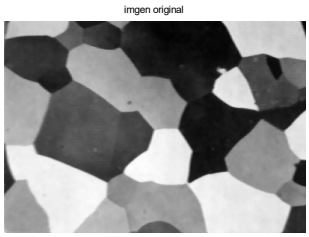


Centroides definitivos

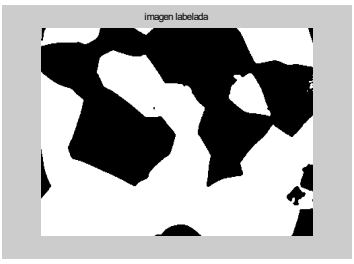
Umbrales definitivos

Métodos de *clustering*
Algoritmo k-means

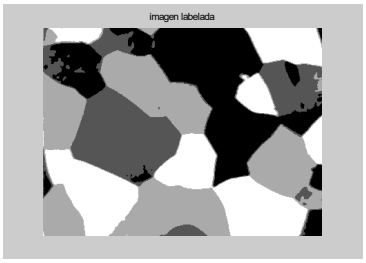
- Resumen del algoritmo *k-means*: Elegir centroides iniciales → Asignar píxeles → Recalcular centroides → Repetir hasta convergencia.
- La clasificación del algoritmo *k-means* **depende del número de clases** que le indiquemos. Ejemplos:



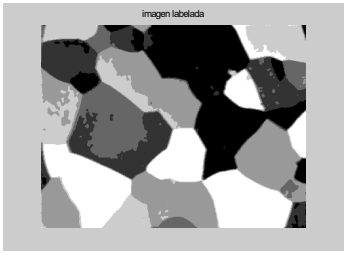
original



2 clases



4 clases



6 clases

Universidad de Alcalá

Métodos de *clustering*
Algoritmo k-means

- **Ventajas**:
  - Algoritmo sencillo y muy eficiente.
- **Inconvenientes**:
  - Se necesita saber el **número de clases** *a priori*.
  - **Converge a una solución local y depende de la inicialización**: distintas posiciones iniciales de los centroides pueden producir resultados diferentes.
  - Funciona mejor con **clústeres compactos y de dispersión similar:** puede presentar problemas con distribuciones de formas, tamaños o dispersiones muy diferentes.

Segmentación basada en histograma

Ventajas:

- Aplicación **simple y rápida.**
- Los umbrales pueden obtenerse de forma **no** supervisada.
- Buenos resultados con imágenes **simples** e iluminación controlada.
- Puede aplicarse al **seguimiento** de objetos en secuencias.

Inconvenientes:

- Los métodos de umbralización **global** pueden dar malos resultados cuando la iluminación no es uniforme.
- El **solapamiento** entre las distribuciones de las clases produce errores de clasificación.
- El histograma **no** contiene información sobre la **posición** ni la **conectividad** de los píxeles:
  - pueden aparecer **agujeros** en las regiones,
  - **píxeles aislados** de una clase dentro de otras.

Bibliografía

- [Bergasa et al.,00]L.M. Bergasa, M. Mazo, A. Gardel, M. A. Sotelo, L. Boquete, "Unsupervised and adaptative Gaussian skin-color model", Image and Vision Computing (Editorial Elsevier), Number 18, pages 987 to 1003, September of 2000.
- [Campbell et al. 96] N.W. Campbell,B.T. Thomas and T. Troscianko. "Segmentation of Natural Images using Self_Organising Feature Maps". In British Machine Vision Conference, pages 223_232. British Machine Vision Association, September 1996.
- [Gath et al.,89] I. Gath and B. Geva. "Unsupervised Optimal Fuzzy Clustering". IEEE Trans. Pattern Analysis and Machine Intelligence", Vol.11, Nº7, pp.773-781, July 1989.
- [Kohonen, 97] T. Kohonen, "Self Organizing Maps", Springer, Berlin, 1997.
- [Lagan et al.,98] D.A. Lagan, J.W. Modestino and J.Zhang. "Cluster Validation for Unsupervised Stochastic Model-Bases Image Segmentation". IEEE Transactions on Image Processing, Vol. 7, Nº2, pp. 180-195, February, 1998
- [Littmann&Ritter, 97]E. Littmann and H. Ritter, "Adaptive Color Segmentation-A comparation of Neural and Statistical Methods", IEEE Transactions on Neural Networks, VOL 8, NO 1, January 1997.
- [Oliver et al.,00]N. Oliver, A. Pentland, F. Berard, "LAFTER: a real-time face and lips tracker with facial expression recognition". Pattern Recognition 33, pp:1369-1382, 2000.
- [Rissanen, 78] J. Rissanen. "Modeling by Shortest Data Description", Automatica, Vol.14, pp. 465-471, 1978.
- [Roberts et al., 98]S.J. Roberts, Dirk Husmeier, Iead Rezek and William Penny. "Bayesian Approaches to Gaussian Mixture Modeling". IEEE Transactions on Image Processing, Vol. 20, Nº11, pp.1133-1142, November, 1998
- [Stiefelhagen et al., 97a] Stiefelhagen, J. Yang and A. Waibel "A model based gaze tracking system". IEEE International Joint Symposia on Intelligence and Systems-Image, Speech&Natural Language Systems. 1997
- [Yamazaki, 98]T. Yamazaki, "Introduction of EM algorithm into color image segmentation", Proc. ICIPS'98, pp:368-371, August, 1998.
- [Yang&Waibel, 97], J. Yang, A. Waibel, "Skin-Color Modeling and Adaptation", Technical Report CMU-CS-97-146. School of Computer Science. Carnegie Mellon University, 1997.
- [Zhu et al., 00] X. Zhu, J. Yang, A. Waibel, "Segmenting Hands of Arbitrary Color", Fourth IEEE International Conference on Automatic Face and Gesture Recognition (F&G),pp: 446-453, 2000