Universidad de Alcalá



3. Segmentación basada en regiones

Segmentación basada en regiones
Formulación básica

- La **segmentación en regiones** de una imagen, f(u,v) definida sobre la región R, es un proceso de partición de R en un conjunto de K regiones $\{R_i\}$, $1 \le i \le K$, tales que:
  - **Coherencia de características** ⟶ Que alguna característica cumpla un predicado de homogeneidad (condición) para cada región (objeto):

    $P(R_i)$ es CIERTO para $i = 1,2,\ldots,K$

    $P(R_i \cup R_j)$ es FALSO para R_i y R_j adyacentes e $i \neq j$

    P. ej. que la diferencia entre el nivel de gris mínimo y máximo de los píxeles de la región sea menor que un umbral ($P(R_i)$: $\max I(R_i) - \min I(R_i) \le T$).
  - **Coherencia espacial** ⟶ R_i es una región conectada o conexa (los píxeles son contiguos).
  - **Ningún píxel pertenece a más de una región**:

    ⟶ $R_i \bigcap R_j = \varnothing \ \forall i, j \ ; i \neq j$
  - La **unión** de todas las regiones forma la **imagen** ⟶ $R = \bigcup_{i=1}^{K} R_i$

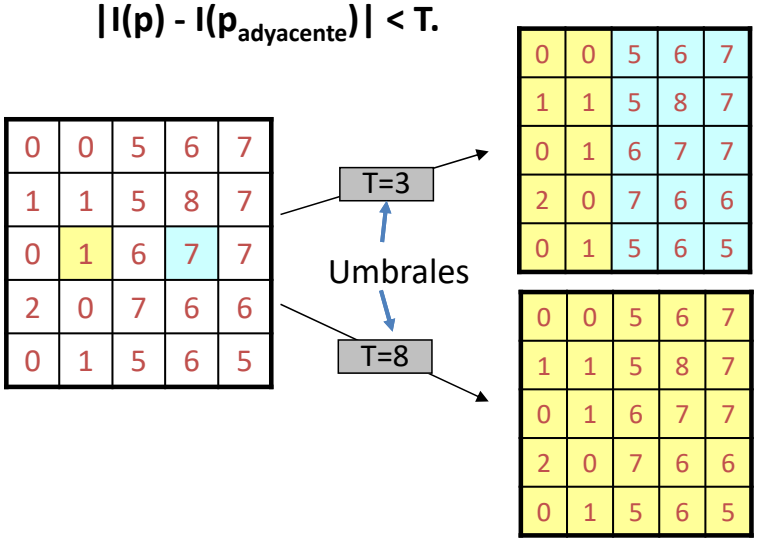
Método de crecimiento de regiones:

1. Para **segmentar** la imagen se comienza eligiendo un conjunto de puntos **semilla** (manual o automáticamente).
2. Se va haciendo **crecer cada región** a partir de su punto semilla añadiendo aquellos píxeles que cumplan las siguientes dos condiciones:
   - Que sean **adyacentes** a la región.
   - Que cumplan un **criterio de similitud u homogeneidad**, por ejemplo, en el nivel de gris, textura, etc.
3. Si quedan píxeles sin clasificar, se seleccionan **nuevas semillas** entre ellos y se vuelve al punto 2.
4. El proceso continúa hasta que **no** queden píxeles por clasificar.
5. **Postprocesado**: si hay regiones muy pequeñas, se pueden unir con regiones vecinas similares (para evitar excesiva fragmentación, eliminar ruido, suavizado de límites, etc.).

Criterio de similitud: ¿Cuándo se considera un píxel similar para ser añadido a una región?

- Dos posibles criterios son:
  - cuando la **diferencia del valor de la característica (nivel de gris)** con respecto al píxel **adyacente** es inferior a un **umbral** (T)
  - cuando la **diferencia del valor de la característica** con respecto a una **estadística** de toda la región, como su media, es inferior a un **umbral** (T).

- Ej.: Consideremos que la característica utilizada es el **nivel de gris** (I) y el criterio es que un píxel vecino p se añade a la región si cumple el criterio de similitud: $|I(p) - I(p_{adyacente})| < T$.



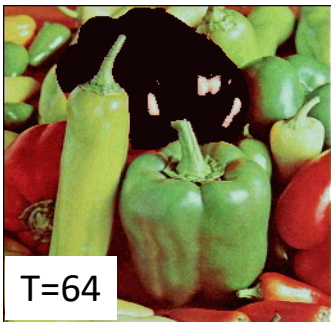
- Ejemplo de crecimiento de regiones con distintos umbrales:

Punto semilla





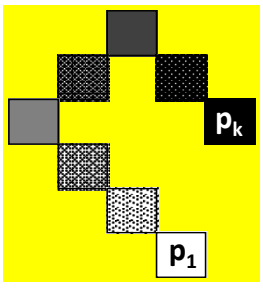






Universidad de Alcalá
Segmentación basada en regiones
Crecimiento de regiones

- **Problemas**:
  - Selección de las **semillas** iniciales (número y ubicación).
  - Criterio de **similitud**:
    - **Características** a tener en cuenta (color, movimiento, etc.).
    - Fijación del **umbral**.
  - **Deriva:** Si vamos incorporando a la región píxeles de valor similar a su vecino → esas pequeñas diferencias sucesivas se acumulan y al final acaban perteneciendo a la región píxeles con características muy diferentes.



Secuencia de píxeles: $p_1, \ldots, p_k$
en todos los pares p_j, p_{j+1} se cumple $|I(p_j) - I(p_{j+1})| < T$
pero $|I(p_1) - I(p_k)| > T$

Segmentación basada en regiones
Splitting and Merging Regions

- El método de **división y fusión de regiones (*splitting and merging*):** en una primera fase divide (*split)* la imagen en regiones y después fusiona (*merge*) las adyacentes que satisfacen algún criterio de similitud.
- **Proceso (I):**
  1. Partición **inicial**: La imagen completa (todos los píxeles) se considera como una región inicial (R).
  2. Se aplica un **predicado de homogeneidad** P(R) para decidir si una región R es suficientemente **uniforme** (una condición booleana definida sobre todos los píxeles de la región).
     Ejemplo de predicados:

$$P(R) = (\max(I(R)) - \min(I(R)) \leq T)$$

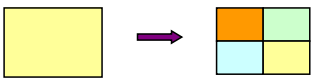
El rango de intensidades dentro de la región es pequeño.

$$P(R) = \left(\sigma^2\left(I(R)\right) < T\right)$$

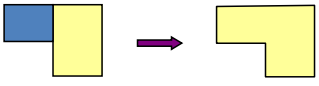
La varianza de los niveles de gris es baja.

Segmentación basada en regiones
Splitting and Merging Regions

- **Proceso (II):**
  3. **Fase de división (*split*):** Si el predicado **no** se cumple, es decir, $P(R_i)$=falso (p. ej. **(max(I(R))−min(I(R))>T)** → ***split*, se divide cada región de forma geométrica**. Se aplica también a **todas las regiones** que se creen, hasta que todas cumplan el criterio.
     La división geométrica puede **generar sobresegmentación**.



  4. **Fase de fusión (*merge*):** dos regiones adyacentes R_i, R_j **se fusionan** si la región unida **cumple el predicado $P(R_i \cup R_j)$:**
     Si $P(R_i \cup R_j)$ = verdadero → $(\max(I(R_i \cup R_j)) - \min(I(R_i \cup R_j)) \leq T)$ → *merge*.
     Se repite tantas veces como sea necesario.
     La fase de *merging* **reduce** la **sobresegmentación** producida en la fase de *splitting.*



  5. El proceso termina cuando todas las regiones cumplen el predicado de homogeneidad y no es posible realizar más divisiones ni más fusiones.

Segmentación basada en regiones
Splitting and Merging Regions

- **Ejemplo de funcionamiento (I)**
  - Definición del criterio de similitud:

$C_{R_i} = \max(I(R_i)) - \min(I(R_i))$

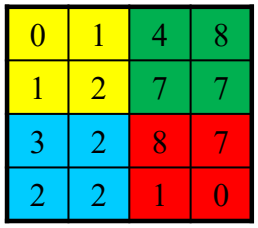
$P(R_i)$: $C_{R_i} \leq T$. En el ejemplo, $T = 3$.

Split si $C_{R_i} > T$

Quadimages

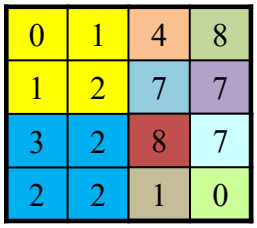
0	1	4	8
1	2	7	7
3	2	8	7
2	2	1	0

$C_R = 8$

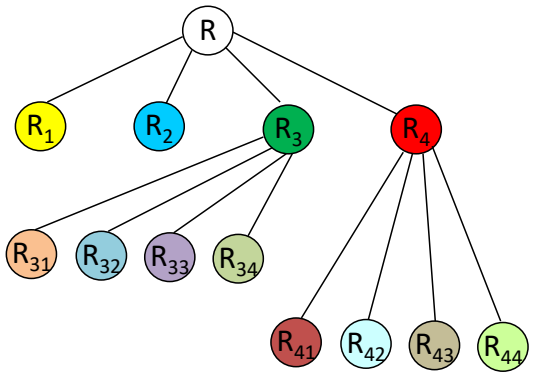


$C_{R_1} = 2$ $C_{R_3} = 4$

$C_{R_2} = 1$ $C_{R_4} = 8$



Quadtree

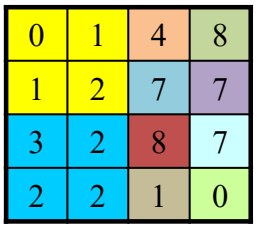


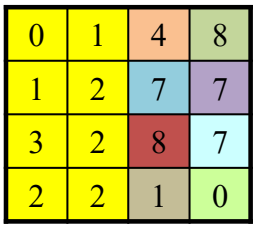
Fin de la fase de *splitting*: todas las regiones cumplen el criterio: ya no es necesario realizar más divisiones.

Segmentación basada en regiones
Splitting and Merging Regions

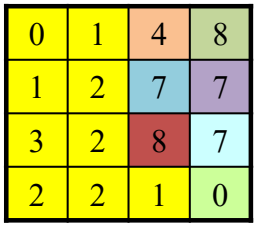
- **Ejemplo de funcionamiento (II)**

Merge si $(C_{R_i \cup R_j}) \leq T$

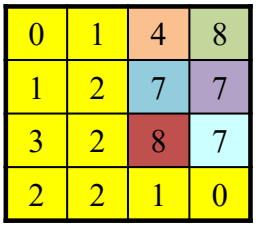




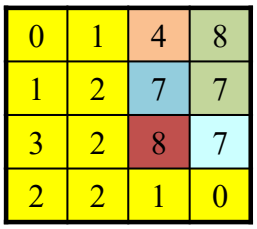
$C_{R_1 \cup R_2} = 3$



$C_{R_1 \cup R_{43}} = 3$

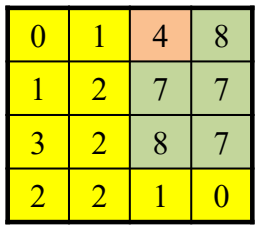


$C_{R_1 \cup R_{44}} = 3$

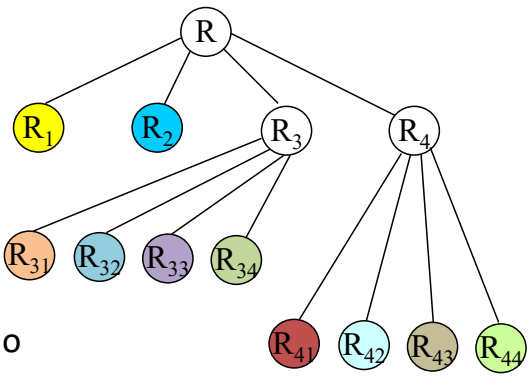


$C_{R_{34} \cup R_{33}} = 1$

...



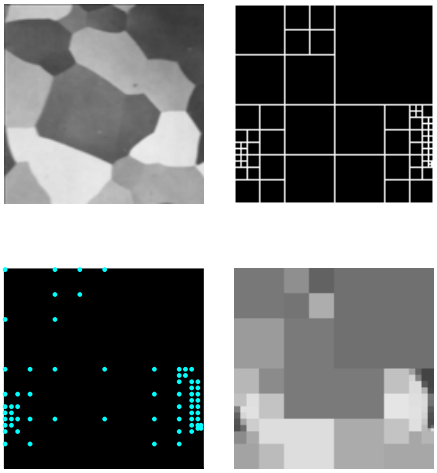
$C_{R_{34} \cup R_{41}} = 0$



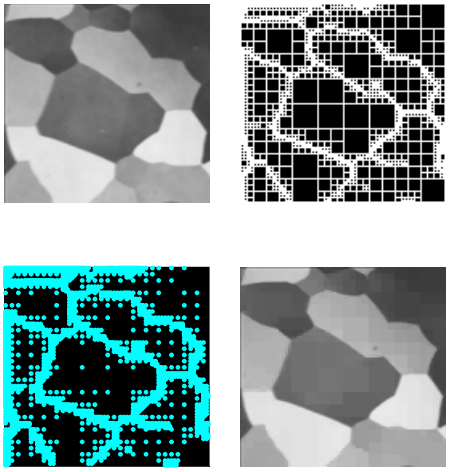
Seguimos hasta que ninguna unión cumpla el criterio de fusión, reduciendo la sobresegmentación.

Segmentación basada en regiones
Splitting and Merging Regions

- Ventajas:
  - Simple.
  - No requiere selección de semillas.
  - Evalúa la homogeneidad de las regiones completas.
- Inconvenientes:
  - Dependencia del umbral.
  - División puramente geométrica.
  - Puede generar contornos poco naturales.



Umbral = 0.6



Umbral = 0.1

Segmentación basada en regiones
Transformada Watershed

- **Transformada Watershed.** Es especialmente útil para separar **objetos convexos (con forma circular, ovalada, etc.) que se tocan** en una imagen (pueden ser difíciles de separar por otros métodos).
- Aplica conceptos **topográficos** para segmentar. El algoritmo simplificado es:
  - Se **umbraliza** la imagen en niveles de gris, para obtener una imagen en blanco (objeto) y negro (fondo).
  - Se calcula **la transformada de distancia**: a cada píxel del objeto se le asigna su distancia al fondo o borde más próximo. Interpretación topográfica de la imagen de la distancia:
    - Niveles de gris bajos indican puntos muy cercanos a los bordes.
    - Niveles de gris altos indican puntos más alejados de los bordes
    - Los máximos locales son aproximadamente los centros de los objetos.
  - Para aplicar ***watershed***, se invierte la distancia, se interpreta como **profundidad**, y los máximos locales se convierten en mínimos y se interpretan como los centros de valles (***catchment basins*, cuencas hidrográficas**).
  - Se llena cada valle con agua de un color diferente empezando por su centro.
  - El agua sube en las cuencas hasta encontrarse con la de otros valles.
  - Las líneas *watershed*, **barreras (*watershed ridge*),** que se crean entre las cuencas para que el agua no se mezcle, forman **el resultado de la segmentación**.

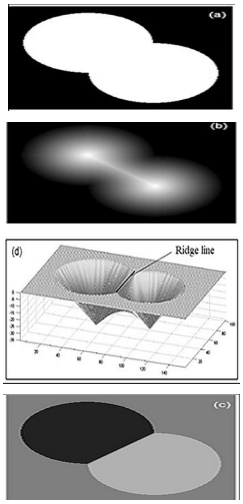
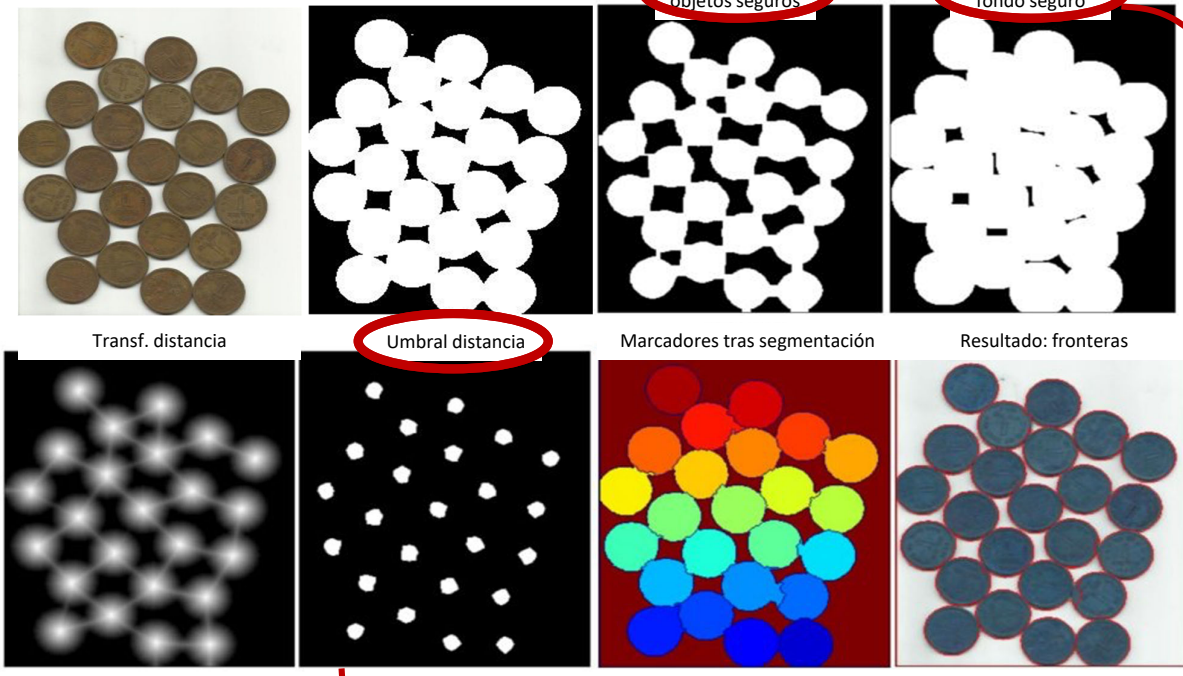


Imagen modificada del siguiente enlace.

- **Problema:** el ruido o las irregularidades en los bordes pueden generar máximos locales en las distancias produciendo **sobresegmentación.**
- **Solución** a la sobresegmentación: **preprocesar** la imagen (antes de aplicar el algoritmo) con **operadores morfológicos** (erosión, dilatación, etc.), que pueden **reducir el ruido** y ayudarnos a obtener regiones que sabemos con seguridad **que son objetos o fondo** a partir de los que se pueden construir **los marcadores** (ver ejemplo siguiente).

Segmentación basada en regiones
Transformada Watershed (ejemplo)



Las operaciones morfológicas nos permiten seleccionar automáticamente píxeles que sabemos con seguridad que pertenecen a objetos y al fondo

Se umbraliza la imagen de distancia para obtener regiones interiores seguras de objetos y se asigna automáticamente una etiqueta distinta a cada componente conexa → **marcadores**. Después, a partir de la posición de los marcadores, se van creciendo las regiones sobre la superficie de distancia invertida y se determinan las fronteras entre objetos.

Segmentación basada en regiones
Transformada Watershed

- **Ventajas:**
  - Buen funcionamiento para segmentar múltiples objetos que se tocan, aunque tengan niveles de gris similares (pueden ser difíciles de segmentar con otros métodos más sencillos como la umbralización o crecimiento de regiones).

- **Inconvenientes:**
  - Método complejo.
  - Sensible al ruido y a pequeños máximos y mínimos locales: puede producir sobresegmentación.
  - El resultado puede depender del preprocesamiento y de la obtención de los marcadores adecuados.

Bibliografía

- http://www-2.cs.cmu.edu/afs/cs/project/cil/ftp/html/vision.html (Computer Vision Homepage CMU)
- http://svr-www.eng.cam.ac.uk/milab.html (Machine Intelligence Laboratory. Cambridge University)
- http://www.inria.fr/recherche/equipes/listes/theme_3.en.html (INRIA Vision)
- http://www-white.media.mit.edu/vismod/ (MIT Media Lab)
- http://www.cvc.uab.es (Centro de Visión Artificial. Barcelona)

Universidad de Alcalá



4. Detección de bordes

Detección de bordes
Objetivo

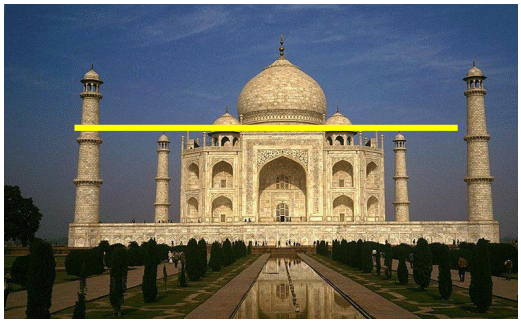
- En imágenes en niveles de gris, los **bordes** de la imagen se asocian con los **cambios de intensidad** significativos que haya en ella. En general, se corresponden con cambios en alguna característica.
- Las causas suelen ser:
  - Discontinuidades en la superficie.
  - Discontinuidades en la profundidad.
  - Discontinuidades en el color o en la textura de la superficie.
  - Discontinuidades en la iluminación, sombras, reflexiones...
- Nuestro objetivo será crear algoritmos para la **detección de bordes (*edges*) significativos** de una imagen, ya que de estos bordes pueden extraerse características importantes de la imagen que nos ayuden en las siguientes etapas del sistema de visión artificial (segmentación, reconocimiento...).

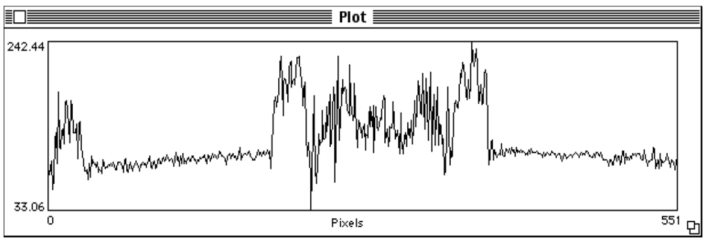


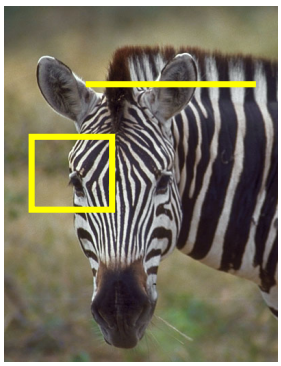


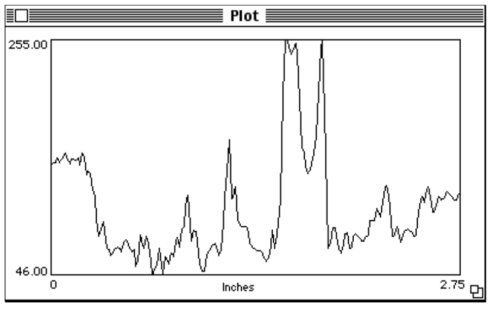
Bordes
Ejemplos

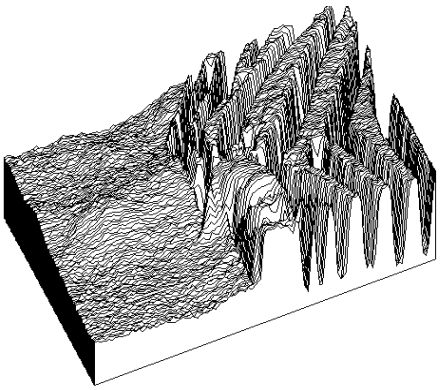
- Ejemplos donde se pueden ver los cambios de intensidad de los píxeles:











Detección de bordes
Objetivo

- No está claro qué es un **borde significativo:**
  - En parte definido por el **contexto** en el que se están aplicando los detectores de bordes.

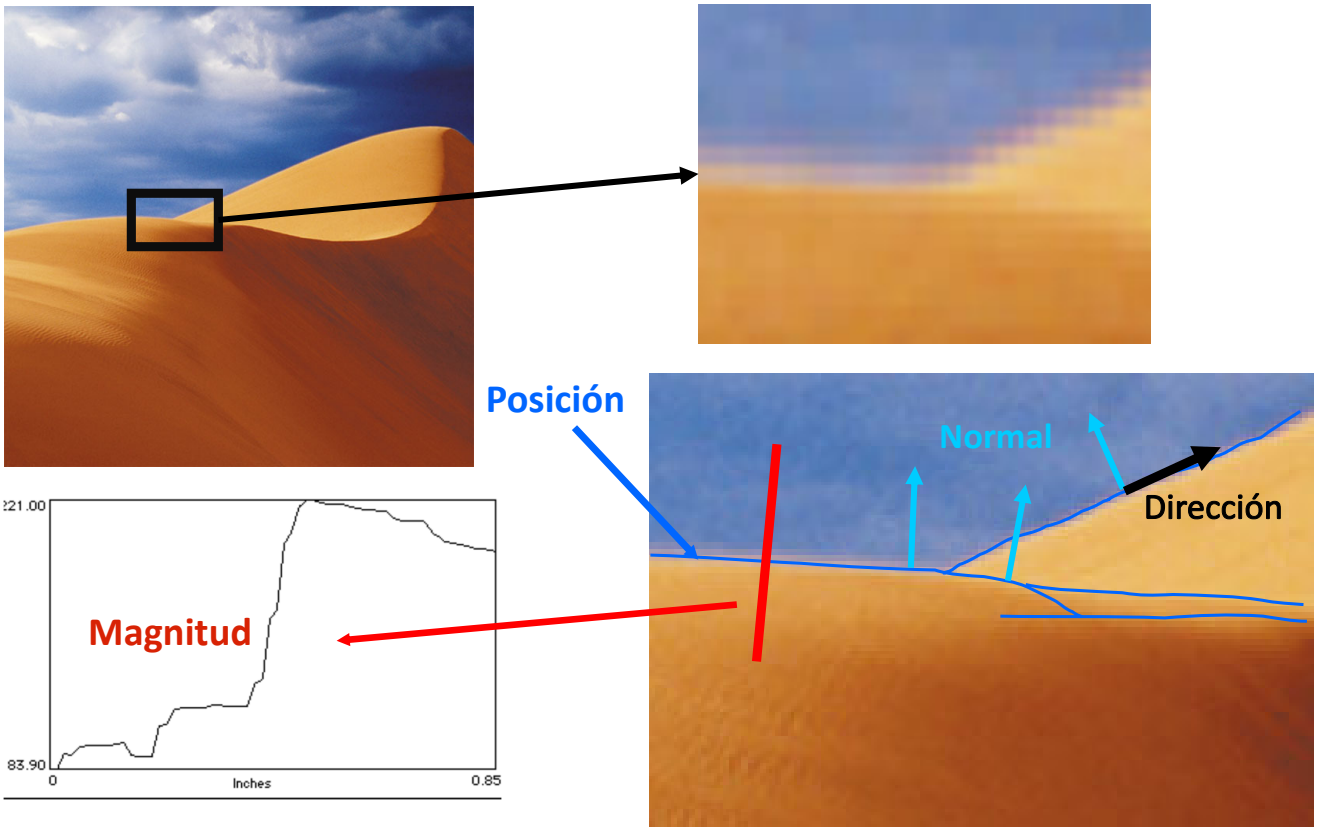




Detección de bordes
Bordes locales ("edgels")

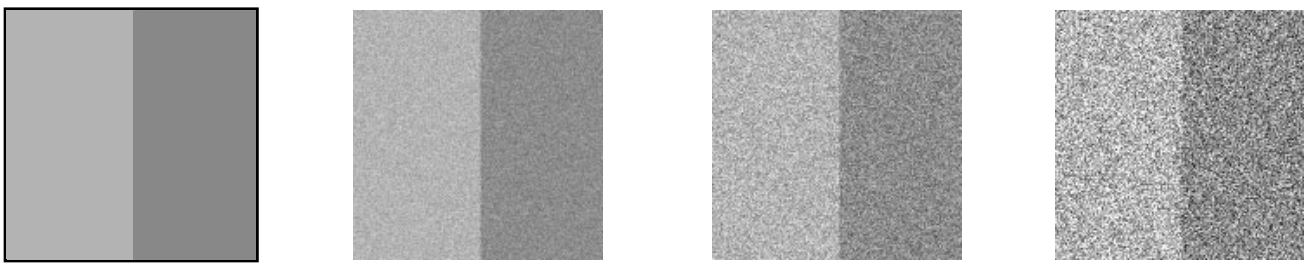
- Los ***edgels*** **(*edge+pixels*)** son **píxeles** cuyo nivel de gris es significativamente diferente al de sus vecinos.
- Un **borde local** implica que hay un cambio rápido en una imagen dentro de un área pequeña.
- ***Edgels*** son **píxeles**, **no** son contornos, límites ni líneas:
  - Los *edgels* sirven de soporte para definir contornos, límites o líneas.
  - Contornos, límites o líneas se construyen a partir de los *edgels*, agrupando varios *edgels* conectados.
- **Propiedades de los bordes**:
  - **Posición**: posición de la imagen en la cual se localizan los bordes.
  - **Normal***:* vector unitario en la dirección de máxima variación de intensidad (la dirección del gradiente de intensidad).
  - **Dirección***:* vector unitario perpendicular al vector normal.
  - **Magnitud***:* indica cómo de rápido varía la intensidad en el borde, en la dirección de la normal. Está relacionada con el gradiente local.

Bordes
Propiedades



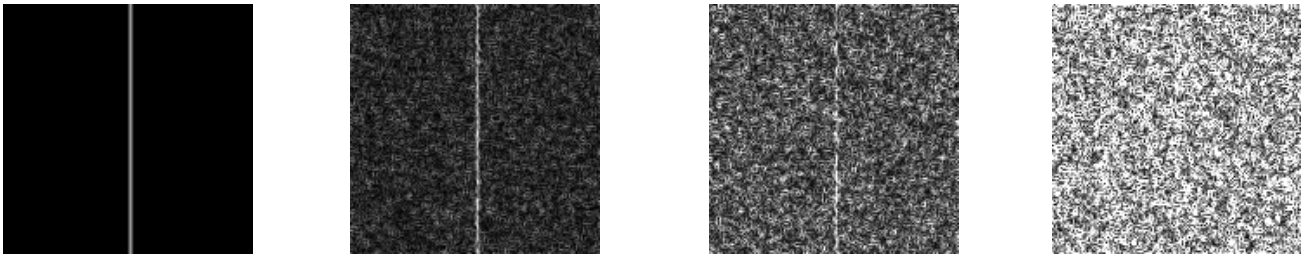
Bordes
Efecto del ruido

Imagen ideal **Imagen con ruido**



Aumento de ruido →

Bordes detectados



Bordes

Pasos a seguir en la detección de bordes

1. **Eliminación de ruido**
   - Suprimir todo lo que se pueda el ruido mientras se mantengan los bordes.
   - En ausencia de otro tipo de información, se supone que el ruido es "blanco" con distribución gaussiana.
2. **Realce de bordes**
   - Diseñar filtros que respondan bien a los bordes: filtros que proporcionen valores elevados donde existan bordes y valores bajos en el resto.
3. **Localización de bordes**
   - Determinar qué píxeles deberían ser descartados por representar ruido y cuáles se deben mantener:
     - Adelgazamiento de los bordes, p. ej. mediante supresión no máxima.
     - Establecer un valor mínimo para considerar que un máximo local de un filtro es un borde (umbralización).

Bordes

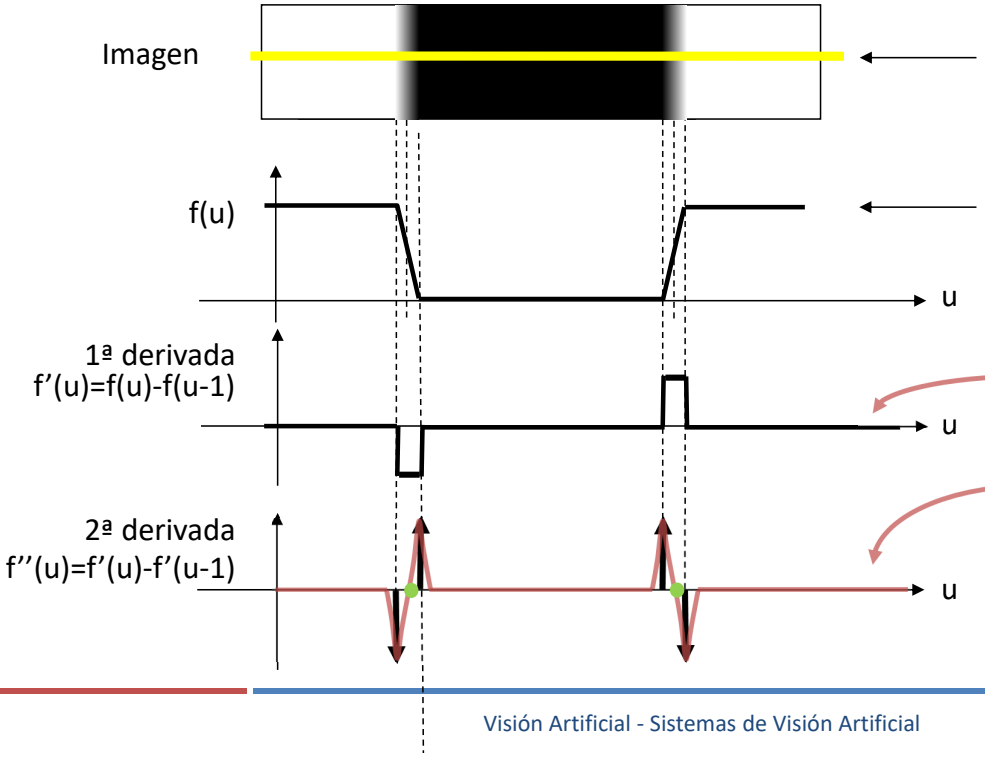
Métodos de detección

- **Estimación de la primera derivada:**
  - Detectores de bordes tipo ***"gradiente".***
  - Detectores de bordes tipo ***"orientación" (brújula o compás).***
  - Detectores de bordes tipo ***"Canny".***
- **Segunda derivada:**
  - Laplaciana.
  - Laplaciana de la Gaussiana.

Bordes

¿Cómo detectar edgels?

- Ejemplo de detección de borde en 1D: detectamos el borde solamente en los píxeles que hay sobre la línea amarilla:



Línea en la que vamos a buscar los bordes 1D (una línea → solo componente u).

Nivel de gris a lo largo de la línea

Para detectar los ***edgels*** podemos calcular:

- **Máximos o mínimos** locales de la **1ª derivada** (son gruesos por la rampa de nivel de gris).
- Los **cruces por cero de la 2ª derivada** (permiten detectar un borde más fino).

"*Edgel*"

Bordes

Operadores primera derivada: gradiente

- El **gradiente** de una imagen *f(u,v)* en un punto *(u,v)* se define como un **vector bidimensional**: Nos dice cuánto cambia el nivel de gris en la dirección u y cuánto en la dirección v.

$$G[f(u,v)] = \begin{bmatrix} G_u \\ G_v \end{bmatrix} = \begin{bmatrix} \frac{\partial}{\partial u} f(u,v) \\ \frac{\partial}{\partial v} f(u,v) \end{bmatrix}$$

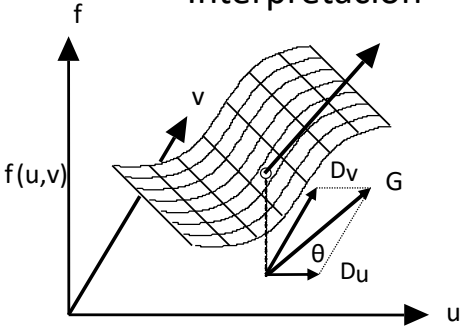
$$\begin{cases} |G| = \sqrt{G_u^2 + G_v^2}, \quad |G| \approx |G_u| + |G_v| \\ \theta(u,v) = \tan^{-1} \frac{G_v}{G_u} \end{cases}$$

- Es perpendicular a la dirección del borde (θ nos proporciona la **normal**).
- Se considera que existe **borde** si la **magnitud** del gradiente **supera un determinado umbral** → ¡Se debe fijar un umbral T!:

$$g(u,v) = \begin{cases} 255 & si \quad |G[f(u,v)| > T \\ 0 & si \quad |G[f(u,v)| \le T \end{cases}$$

Imagen de salida, solo contiene los bordes.

Interpretación



Bordes

Operadores primera derivada: gradiente

- Las derivadas se pueden **aproximar** por:

$$G_u = \frac{\partial f(u,v)}{\partial u} \approx f(u,v) - f(u-1,v)$$

máscara →

0	0	0
-1	1	0
0	0	0

$h_u(u,v)$

u →, v ↓

$$G_v = \frac{\partial f(u,v)}{\partial v} \approx f(u,v) - f(u,v-1)$$

máscara →

0	-1	0
0	1	0
0	0	0

$h_v(u,v)$

$$G_u = \frac{\partial f(u,v)}{\partial u} \approx [f(u+1,v-1) + 2f(u+1,v) + f(u+1,v+1)] - [f(u-1,v-1) + 2f(u-1,v) + f(u-1,v+1)]$$

→

-1	0	1
-2	0	2
-1	0	1

$h_u(u,v)$

$$G_v = \frac{\partial f(u,v)}{\partial v} \approx [f(u+1,v+1) + 2f(u,v+1) + f(u-1,v+1)] - [f(u+1,v-1) + 2f(u,v-1) + f(u-1,v-1)]$$

→

-1	-2	-1
0	0	0
1	2	1

$h_v(u,v)$

Bordes

Operadores primera derivada: gradiente

- ¿Cuál sería el efecto de aplicar las máscaras vistas a las siguientes imágenes?

Imagen 1

2	2	2	2	2	2
2	2	2	2	2	2
2	2	2	2	2	2
2	2	2	2	2	2
2	2	2	2	2	2
2	2	2	2	2	2

Imagen 2

0	0	0	0	0	0
0	0	0	0	0	0
1	1	1	1	1	1
1	1	1	1	1	1
0	0	0	0	0	0
0	0	0	0	0	0

Imagen 3

0	0	1	1	0	0
0	0	1	1	0	0
0	0	1	1	0	0
0	0	1	1	0	0
0	0	1	1	0	0
0	0	1	1	0	0

Imagen 4

2	4	5	4	5	5
1	6	3	6	3	5
0	7	5	7	0	4
5	6	3	7	1	2
3	4	3	5	5	4
4	2	4	2	4	3

Máscaras

1. | | | | |
|---|---|---|---|
| 0 | 0 | 0 | |
| -1 | 1 | 0 | $h_u(u,v)$ |
| 0 | 0 | 0 | |

2. | | | | |
|---|---|---|---|
| 0 | -1 | 0 | |
| 0 | 1 | 0 | $h_v(u,v)$ |
| 0 | 0 | 0 | |

3. | | | | |
|---|---|---|---|
| -1 | 0 | 1 | |
| -2 | 0 | 2 | $h_u(u,v)$ |
| -1 | 0 | 1 | |

4. | | | | |
|---|---|---|---|
| -1 | -2 | -1 | |
| 0 | 0 | 0 | $h_v(u,v)$ |
| 1 | 2 | 1 | |

Bordes

Ejemplo real: gradiente



f(u,v)



$g_1(u,v)=f(u,v)*h_u(u,v)$



$g_2(u,v)=f(u,v)*h_v(u,v)$



$g(u,v)= |g_1(u,v)|+ |g_2(u,v)|$

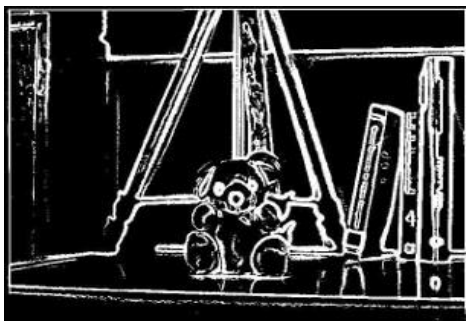
Aproximación al módulo del vector

Bordes

Ejemplo real: gradiente

f(u,v)

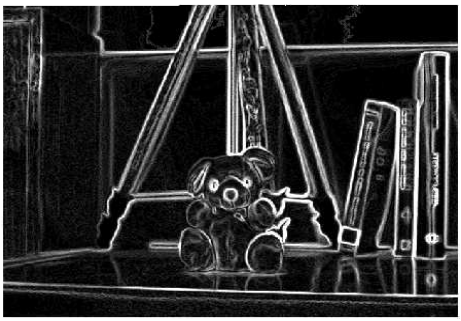




$|G[f(u,v)]|>T$
con T= 30

$g_m(u,v)$

$|G[f(u,v)]|$



θ(u,v)



Bordes

Otros operadores: gradiente

Roberts

$$G_u = \begin{bmatrix} 0 & 0 & -1 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \qquad G_v = \begin{bmatrix} -1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

Prewitt

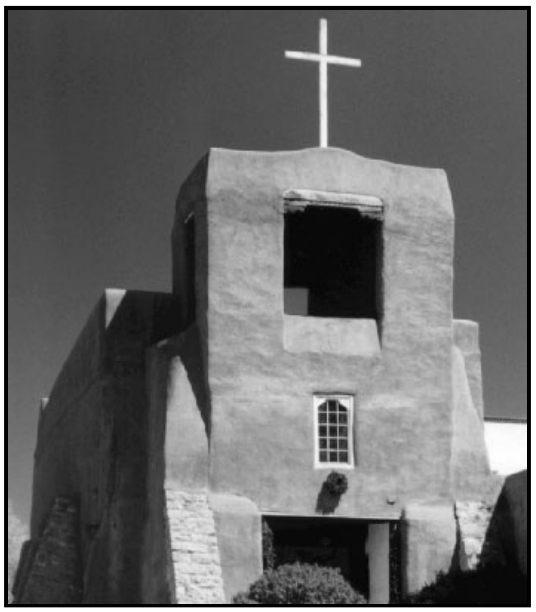
$$G_u = \begin{bmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{bmatrix}, \qquad G_v = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

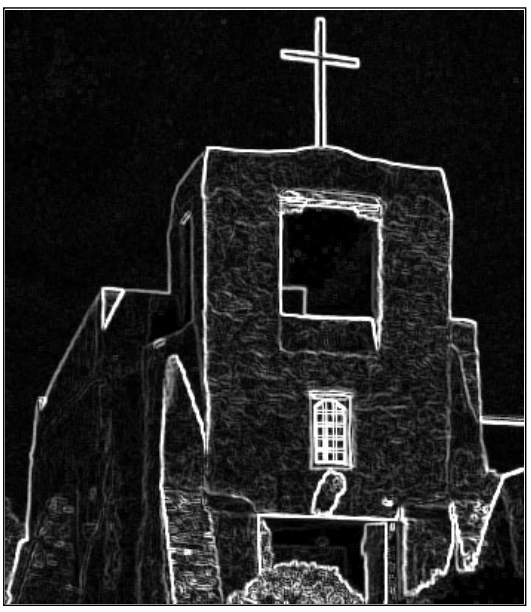
Sobel

$$G_u = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, \qquad G_v = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

Bordes

Ejemplos con máscaras de Prewitt





Bordes

Operadores primera derivada: "orientación"

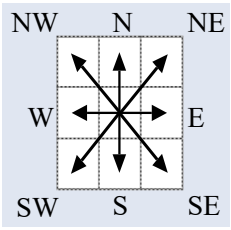
- **Máscaras de Kirsch**:

$$k_0 = \begin{bmatrix} -3 & -3 & 5 \\ -3 & 0 & 5 \\ -3 & -3 & 5 \end{bmatrix}, \; k_1 = \begin{bmatrix} -3 & 5 & 5 \\ -3 & 0 & 5 \\ -3 & -3 & -3 \end{bmatrix}, \; k_2 = \begin{bmatrix} 5 & 5 & 5 \\ -3 & 0 & -3 \\ -3 & -3 & -3 \end{bmatrix}, \; k_3 = \begin{bmatrix} 5 & 5 & -3 \\ 5 & 0 & -3 \\ -3 & -3 & -3 \end{bmatrix}$$

0° 45° 90° 135°

$$k_4 = \begin{bmatrix} 5 & -3 & -3 \\ 5 & 0 & -3 \\ 5 & -3 & -3 \end{bmatrix}, \; k_5 = \begin{bmatrix} -3 & -3 & -3 \\ 5 & 0 & -3 \\ 5 & 5 & -3 \end{bmatrix}, \; k_6 = \begin{bmatrix} -3 & -3 & -3 \\ -3 & 0 & -3 \\ 5 & 5 & 5 \end{bmatrix}, \; k_7 = \begin{bmatrix} -3 & -3 & -3 \\ -3 & 0 & 5 \\ -3 & 5 & 5 \end{bmatrix}$$

180° 225° 270° 315°



- Para cada píxel f(u,v):
  - $|G[f(u,v)]| = \max\{|k_0 * f(u,v)|, |k_1 * f(u,v)|, \ldots, |k_7 * f(u,v)|\} = \max\{|k_i * f(u,v)|\}$.
  - Θ = ángulo de la normal al borde correspondiente a $\max\{|k_i * f(u,v)|\}$.

Bordes

Operadores primera derivada: "orientación"

- **Ejemplo de aplicación de las máscaras de Kirsch (I)**: (x: imagen de entrada, y: módulo de la aplicación de la máscara de Kirsch)

x = 7×7

1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1

y = 7×7

0	0	0	0	0	0	0
0	0	0	0	0	0	0
0	0	0	0	0	0	0
0	0	0	0	0	0	0
0	0	0	0	0	0	0
0	0	0	0	0	0	0
0	0	0	0	0	0	0

Imagen entrada



Imagen de bordes



x = 7×7

1	1	1	1	1	1	1
1	1	1	1	1	1	1
0	0	0	0	0	0	0
0	0	0	0	0	0	0
1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1

y = 7×7

0	0	0	0	0	0	0
15	15	15	15	15	15	15
15	15	15	15	15	15	15
15	15	15	15	15	15	15
15	15	15	15	15	15	15
0	0	0	0	0	0	0
0	0	0	0	0	0	0

Imagen entrada



Imagen de bordes



Bordes

Operadores primera derivada: "orientación"

- **Ejemplo de aplicación de las máscaras de Kirsch (II)**:

x = 7×7

0	0	1	1	1	1	1
0	0	1	1	1	1	1
0	0	1	1	1	1	1
0	0	1	1	1	1	1
0	0	1	1	1	1	1
0	0	1	1	1	1	1
0	0	1	1	1	1	1

y = 7×7

0	15	15	0	0	0	0
0	15	15	0	0	0	0
0	15	15	0	0	0	0
0	15	15	0	0	0	0
0	15	15	0	0	0	0
0	15	15	0	0	0	0
0	15	15	0	0	0	0

Imagen entrada



Imagen de bordes



x = 7×7

0	0	0	0	1	1	1
0	0	0	1	1	1	1
0	0	1	1	1	1	1
0	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1

y = 7×7

0	0	5	12	10	0	0
0	5	15	15	5	0	0
5	15	15	5	0	0	0
12	15	5	0	0	0	0
10	5	0	0	0	0	0
0	0	0	0	0	0	0
0	0	0	0	0	0	0

Imagen entrada



Imagen de bordes

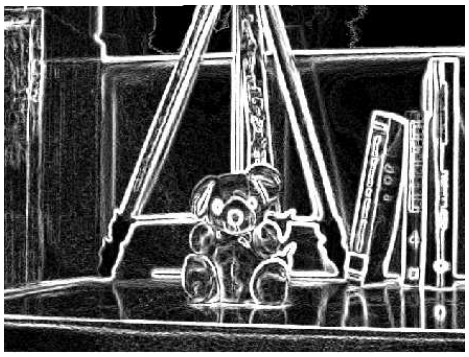


Bordes

Ejemplos con máscaras de Kirsch



|G|



θ



Bordes

Operadores primera derivada: tipo "Canny"

- El **operador de Canny** se basa en los operadores derivada, e introduce otras fases para mejorar la detección.
- Resulta especialmente interesante **porque extrae bordes finos y mejora la continuidad de los bordes** (aunque no puede garantizar el cierre completo).
- Se desglosa en las siguientes fases:
  1. **Suavizado** de la imagen original con **filtro gaussiano (σ)** para reducir el ruido**.**
  2. Obtención del **gradiente** (|G| y θ) en cada píxel.
  3. **Adelgazamiento** del ancho de los bordes, obtenidos con el gradiente, hasta lograr **bordes de un píxel de ancho** (supresión no máxima), obteniendo la imagen **$I_N(u,v)$.**
  4. **Umbralización**: si los píxeles de $I_N(u,v)$ superan cierto umbral serán considerados como bordes. A la hora de definir el valor del umbral debemos tener en cuenta que:
     - Si imponemos un umbral muy alto perdemos parte de los bordes,
     - Si usamos un umbral bajo tomaríamos parte del ruido como bordes.

Bordes

Operadores primera derivada: tipo "Canny"

- **Solución: Histéresis de umbral.** Fijar **dos umbrales** T_1 y T_2 con $T_1 < T_2$:
  4. Bis Umbralizar todos los puntos de $I_N(u,v)$ aplicando T_1 y T_2 de la siguiente forma:
     - Localizar los puntos que:
       - **sean bordes fuertes: $I_N(u,v) > T_2$ (*strong edge pixels*)** y
       - **sean bordes débiles: $T_1 < I_N(u,v) < T_2$ (*weak edge pixels*).**
     - Consideraremos **bordes** válidos:
       - todos los **bordes fuertes,** y,
       - los **bordes débiles conectados a bordes fuertes** (¡pero no los demás!).
     - De esta forma, obtenemos una detección mucho más **limpia,** en la que desaparecen muchos de los *edgels* débiles, frecuentemente debidos al ruido.
     - La salida es un conjunto de **bordes finos, con buena conectividad.**
  5. En algunas aplicaciones, puede realizarse posteriormente un postprocesado para **cerrar los contornos** que pudiesen haber quedado abiertos por problemas de ruido (con dilatación-erosión, interpolación, etc.).

Bordes

Operadores primera derivada: tipo "Canny"

Ejemplos de aplicación sobre la misma imagen del filtro de Canny con diferentes valores para el filtro gaussiano (σ) y para los umbrales T_1, T_2.

Imagen original



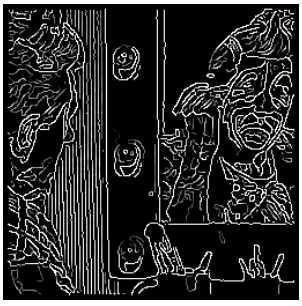
σ=1, T_2=255, T_1=1



σ=1, T_2=255, T_1=220



σ=1, T_2=128, T_1=1



σ=2, T_2=128, T_1=1



Probar distintos pasos en: http://bigwww.epfl.ch/demo/ip/demos/edgeDetector/

Bordes

Segunda derivada: Laplaciana

- Operador segunda derivada: **laplaciana (I)**

$$\nabla^2 f(u,v) = \frac{\partial^2 f(u,v)}{\partial u^2} + \frac{\partial^2 f(u,v)}{\partial v^2}$$

- Se aproxima con máscaras, que deben cumplir que la suma de todos sus elementos sea igual a 0. Diferentes dependiendo de la conectividad:
  - Para conectividad 4:

$$\nabla^2 f(x,y) \approx f(x+1,y)+f(x-1,y)+ f(x,y-1)+f(x,y+1)-4f(x,y)$$

$$\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

  - Para conectividad 8:

$$\nabla^2 f(x,y) \approx f(x+1,y)+f(x-1,y)+f(x,y-1) +f(x,y+1)+f(x+1,y+1)+f(x+1,y-1) +f(x-1,y+1)+f(x-1,y-1)-8f(x,y)$$

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & -8 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

Bordes

Segunda derivada: Laplaciana

- Operador segunda derivada: **laplaciana (II)**
  - Para detectar variaciones de intensidad en un entorno mayor, se pueden utilizar máscaras más grandes, que también sumen 0.
  - Ejemplos:

$$h = \begin{bmatrix} -1 & -1 & -1 & -1 & -1 \\ -1 & -1 & -1 & -1 & -1 \\ -1 & -1 & 24 & -1 & -1 \\ -1 & -1 & -1 & -1 & -1 \\ -1 & -1 & -1 & -1 & -1 \end{bmatrix} \qquad h = \begin{bmatrix} -1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 \\ -1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 \\ -1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 \\ -1 & -1 & -1 & 8 & 8 & 8 & -1 & -1 & -1 \\ -1 & -1 & -1 & 8 & 8 & 8 & -1 & -1 & -1 \\ -1 & -1 & -1 & 8 & 8 & 8 & -1 & -1 & -1 \\ -1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 \\ -1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 \\ -1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 \end{bmatrix}$$

  - Pueden también tener los signos invertidos (los bordes obtenidos tendrán los signos contrarios).
  - Son muy sensibles al ruido.

Bordes

Ejemplo: Laplaciana



Máscara 5x5

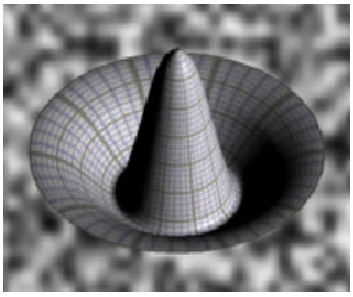


Máscara 9x9

Bordes

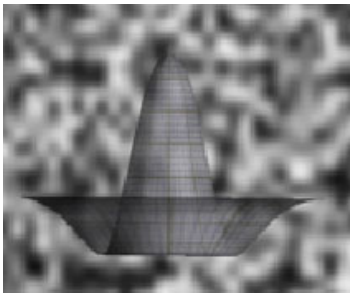
Segunda derivada: Laplaciana de la Gaussiana

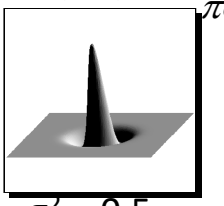
- **Filtro LoG (Laplacian of Gaussian, laplaciana de la gaussiana), operador sombrero mexicano.**
  - Combina dos pasos en una sola matriz:
    - Aplica un filtro gaussiano para suavizar la imagen (reducir ruido).
    - Aplica el laplaciano para detectar los bordes.
  - Es menos sensible al ruido.



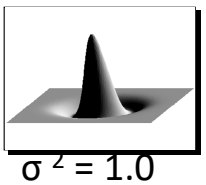
$$G(u,v) = \frac{1}{2\pi\sigma^2}\exp\left[-\frac{(u^2+v^2)}{2\sigma^2}\right]$$

$$\nabla^2 G(u,v) = -\frac{1}{\pi\sigma^4}\left[1-\frac{(u^2+v^2)}{2\sigma^2}\right]\exp\left[-\frac{(u^2+v^2)}{2\sigma^2}\right]$$

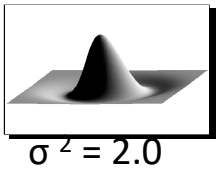




$\sigma^2 = 0.5$



$\sigma^2 = 1.0$



$\sigma^2 = 2.0$

Bordes

Segunda derivada: Laplaciana de la Gaussiana

$$\nabla^2\{f(u,v) * G(u,v)\} = \nabla^2 G(u,v) * f(u,v)$$

Convolución bidimensional

$$\begin{bmatrix} h_{11} & h_{12} & \dots & \dots & h_{1N} \\ h_{21} & h_{22} & \dots & \dots & h_{2N} \\ . & . & . & .. & . \\ . & . & . & .. & . \\ h_{N1} & h_{N2} & \dots & \dots & h_{NN} \end{bmatrix}$$

Un ejemplo: máscara de 5x5

$$\begin{bmatrix} 0 & 0 & -1 & 0 & 0 \\ 0 & -1 & -2 & -1 & 0 \\ -1 & -2 & 16 & -2 & -1 \\ 0 & -1 & -2 & -1 & 0 \\ 0 & 0 & -1 & 0 & 0 \end{bmatrix}$$

$$\nabla^2\{f(u,v) * G(u,v)\} = G(u) * \left\{f(u,v) * \frac{\partial^2}{\partial v^2} G(v)\right\} + G(v) * \left\{f(u,v) * \frac{\partial^2}{\partial u^2} G(u)\right\}$$

Cuatro convoluciones unidimensionales

Bordes

Ejemplo: Laplaciana de la Gaussiana

Máscara 13x13



Bordes

Segunda derivada: Laplaciana de la Gaussiana

- ¿Cómo se generan las máscaras bidimensionales?

$$\nabla^2 G(u,v) = -\frac{1}{\pi\sigma^4}\left[1-\frac{(u^2+v^2)}{2\sigma^2}\right]\exp\left[-\frac{(u^2+v^2)}{2\sigma^2}\right]$$

1. Fijar el valor de la desviación típica, σ, (esto determinará el tamaño) .
2. Determinar el valor de la ecuación anterior para los diferentes valores de (u, v): u=0, 1,2,… y v= 0, 1, 2,… Dada la simetría sólo hay que calcular en un cuadrante.
3. Escalar los valores y redondear los valores al entero más próximo.
4. Extender el ancho de la máscara de forma que contenga todos los valores distintos de cero después del redondeo.
5. Ajustar de forma simétrica los valores, mediante la suma o resta de valores pequeños hasta conseguir que todos los valores de la máscara sumen cero.

Bordes

Segunda derivada: Laplaciana de la Gaussiana

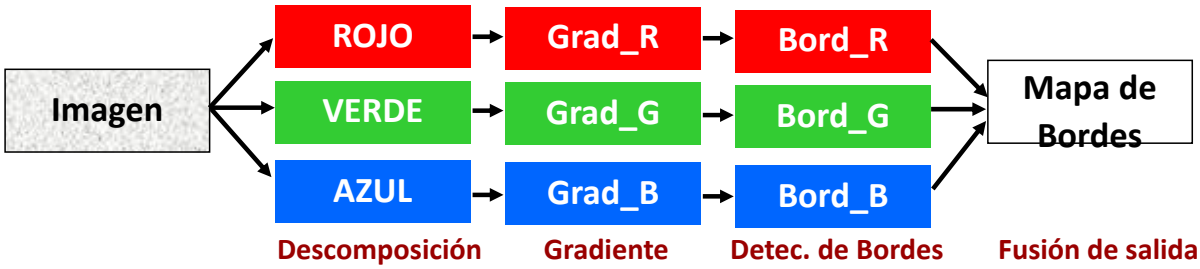
Máscara de 17x17

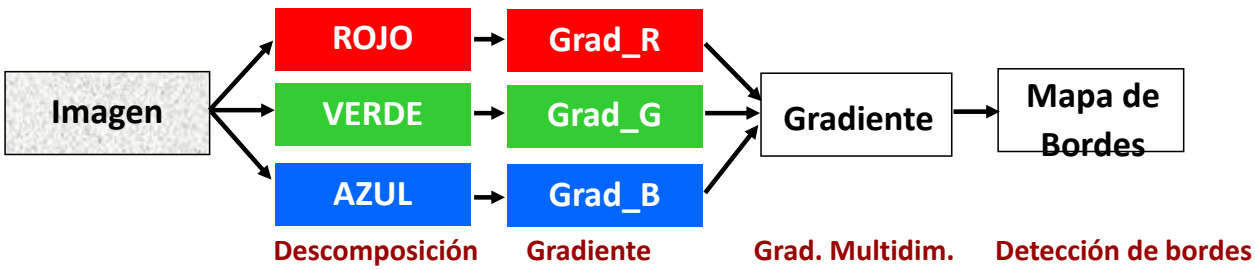
0	0	0	0	0	0	-1	-1	-1	-1	-1	0	0	0	0	0	0
0	0	0	0	-1	-1	-1	-1	-1	-1	-1	-1	-1	0	0	0	0
0	0	-1	-1	-1	-2	-3	-3	-3	-3	-3	-2	-1	-1	-1	0	0
0	0	-1	-1	-2	-3	-3	-3	-3	-3	-3	-3	-2	-1	-1	0	0
0	-1	-1	-2	-3	-3	-3	-2	-3	-2	-3	-3	-3	-2	-1	-1	0
0	-1	-2	-3	-3	-3	0	2	4	2	0	-3	-3	-3	-2	-1	0
-1	-1	-3	-3	-3	0	4	10	12	10	4	0	-3	-3	-3	-1	-1
-1	-1	-3	-3	-2	2	10	18	21	18	10	2	-2	-3	-3	-1	-1
-1	-1	-3	-3	-3	4	12	21	24	21	12	4	-3	-3	-3	-1	-1
-1	-1	-3	-3	-2	2	10	18	21	18	10	2	-2	-3	-3	-1	-1
-1	-1	-3	-3	-3	0	4	10	12	10	4	0	-3	-3	-3	-1	-1
0	-1	-2	-3	-3	-3	0	2	4	2	0	-3	-3	-3	-2	-1	0
0	-1	-1	-2	-3	-3	-3	-3	-3	-3	-3	-3	-3	-2	-1	-1	0
0	0	-1	-1	-2	-3	-3	-3	-3	-3	-3	-3	-2	-1	-1	0	0
0	0	-1	-1	-1	-2	-3	-3	-3	-3	-3	-2	-1	-1	-1	0	0
0	0	0	0	-1	-1	-1	-1	-1	-1	-1	-1	-1	0	0	0	0

Bordes

Detección en imágenes en color

- **Dos alternativas frecuentes:**





Universidad de Alcalá



5. Segmentación Basada en Bordes

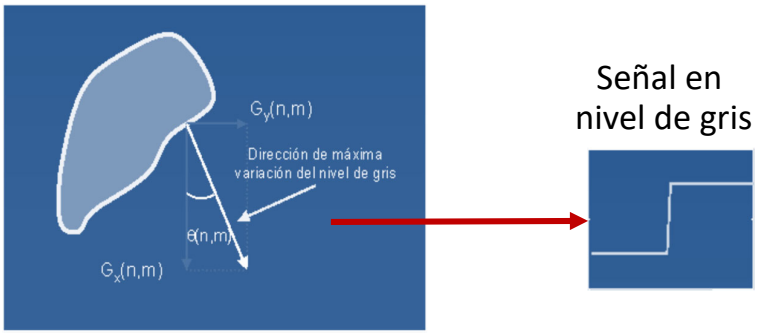
Universidad de Alcalá



5. Segmentación Basada en Bordes: Análisis Local

Segmentación basada en bordes
Análisis Local

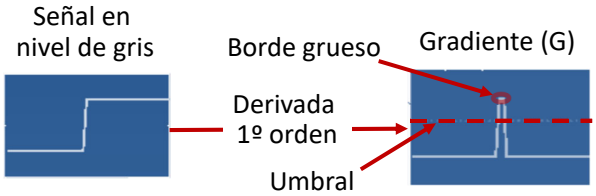
- Hasta ahora hemos visto cómo detectar **bordes** → ahora vamos a ver cómo utilizamos esos bordes para **segmentar regiones**:
  1. Se pasa un filtro **paso alto** por la imagen para detectar los bordes.
  2. Se **umbraliza/binariza** la imagen de bordes y se adelgazan los bordes.
  3. Se busca **conectividad** entre píxeles para detectar **contornos cerrados.**
  4. Cada **contorno cerrado** puede utilizarse para delimitar una **región/objeto**.



Segmentación basada en bordes
Análisis Local

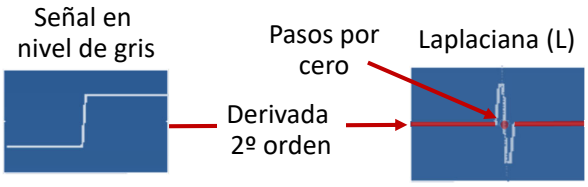
- **Cálculo de bordes y adelgazamiento**:
  - Se **umbraliza** el módulo del **gradiente** para calcular los bordes (pueden quedar bordes **gruesos**):

$$g_1(x,y) = \begin{cases} 1 & si\ G[I(x,y)] > T \\ 0 & si\ G[I(x,y)] \leq T \end{cases}$$



  - Se calcula la laplaciana y los puntos donde dicha **laplaciana pasa por 0**:

$$g_2(x,y) = \begin{cases} 1 & si\ L[I(x,y)] = 0 \\ 0 & si\ L[I(x,y)] \neq 0 \end{cases}$$

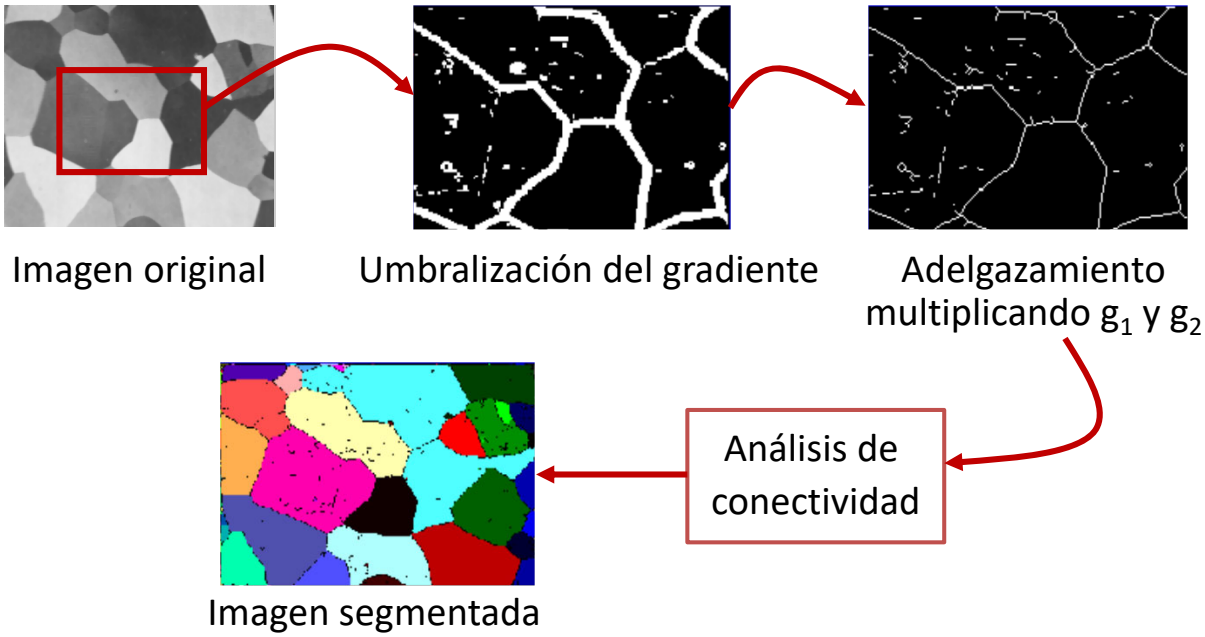


  - Se **adelgazan** los bordes, seleccionando los puntos donde el gradiente supera el umbral (g_1) y la laplaciana pasa por cero (g_2), consiguiendo que los bordes tengan 1 pixel de anchura:

$$g(x,y) = g_1(x,y)\ \&\ g_2(x,y)$$

Segmentación basada en bordes
Análisis Local

- Ejemplo:



Universidad de Alcalá

Segmentación basada en bordes
Análisis Local

- **Ventajas:**
  - Buena localización de los contornos de los objetos.
  - Facilidad de implementación.

- **Inconvenientes:**
  - Dependencia de los umbrales utilizados en la detección.
  - Análisis muy local: definición de regiones depende del cierre de contornos.